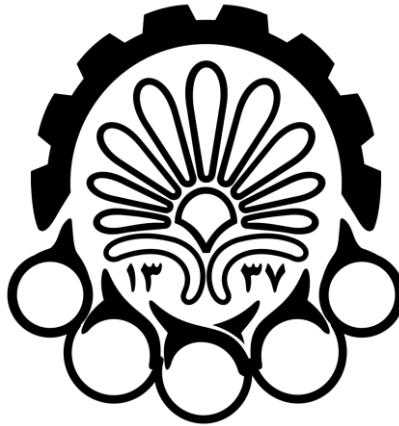


«*In The Name Of GOD*»



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)

[HW-03-Report]

[NEURAL COMPUTING AND DEEP LEARNING]

Hasan Masroor | [403131030] | April 26, 2025

"فهرست مطالب تمرین 03"

Question 1	2
1)	2
2)	12
3)	15
4)	21
5)	22
6)	23

Problem 3: Self Organizing Map (SOM)

:Question 1 

۱.

شبکه خودسازمانده کوهونن (SOM) یک روش یادگیری بدون نظارت است که برای کاهش ابعاد و خوشه‌بندی داده‌ها استفاده می‌شود و با حفظ ساختار داده‌ها، آن‌ها را به فضای کم‌بعدی منتقل می‌کند. در این تمرین هدف اصلی بررسی عملکرد SOM روی داده‌های بانکی است و ما باید ابتدا این شبکه را پیاده‌سازی کنیم و سپس با کاهش ابعاد داده به ۸، ۴ و ۲ بعد، عملکرد آن را با یک دسته‌بند ارزیابی نمایید. همچنین باید تأثیر پارامترهای مختلف مانند اندازه شبکه، نرخ یادگیری و ... را تحلیل کرده و نتایج را با روش‌هایی مثل PCA یا t-SNE مقایسه کنید؛ همچنین از SOM برای خوشه‌بندی داده‌ها بدون برچسب استفاده کرده و کیفیت خوشه‌بندی را با معیارهای استاندارد بسنجیم.

ابتدا کتابخانه‌های مورد نیاز را import کردیم و سپس دیتاست گفته شده را از UCI دریافت کردیم و فایل زیپ را استخراج نمودیم، سپس فایل CSV اصلی را با استفاده از ";" خواندیم و برای نمونه پنج نمونه اول این دیتاست را در خروجی نمایش دادیم:

	age	job	marital	education	default	housing	loan	contact	\
0	56	housemaid	married	basic.4y	no	no	no	telephone	
1	57	services	married	high.school	unknown	no	no	telephone	
2	37	services	married	high.school		no	yes	telephone	
3	40	admin.	married	basic.6y	no	no	no	telephone	
4	56	services	married	high.school		no	no	yes	telephone

	month	day_of_week	...	campaign	pdays	previous	poutcome	emp.var.rate	\
0	may	mon	...	1	999	0	nonexistent	1.1	
1	may	mon	...	1	999	0	nonexistent	1.1	
2	may	mon	...	1	999	0	nonexistent	1.1	
3	may	mon	...	1	999	0	nonexistent	1.1	
4	may	mon	...	1	999	0	nonexistent	1.1	

	cons.price.idx	cons.conf.idx	euribor3m	nr.employed	y
0	93.994	-36.4	4.857	5191.0	no
1	93.994	-36.4	4.857	5191.0	no
2	93.994	-36.4	4.857	5191.0	no
3	93.994	-36.4	4.857	5191.0	no
4	93.994	-36.4	4.857	5191.0	no

[5 rows x 21 columns]

همان طور که در تصویر بالا هم مشاهده می کنیم برخی ستون ها شامل مقادیر unknown هستند و همچنین ترکیبی از ستون های عددی و غیر عددی داریم و قبل از پاسخ به سوال اول لازم است که پیش پردازش های مورد نیاز را انجام دهیم. اگر اندازه دیناست رونمایش دهیم می بینیم که 21 ستون و 41188 ردیف داریم:

```
(41188, 21)
```

در ادامه مقادیر unknown در هر ستون از داده های بانکی را شمارش کردیم و فقط ستون هایی که دارای این مقادیر بودند را نمایش دادیم تا دید کلی از داده های گمشده در مجموعه داده به دست آوریم:

```
Unknown values in each column:  
job           330  
marital        80  
education     1731  
default       8597  
housing        990  
loan          990  
dtype: int64
```

وقتی به تصویر بالا دقت کنیم می بینیم که شش ستون حاوی مقادیر unknown هستند و حال برای هندل کردن این مقادیر، برای هر ستون مقدار unknown را با مُد (برتکرارترین مقدار) همان ستون جایگزین نمودیم تا داده های گمشده را به شکل معنادار پر کنیم و بعدا برای حل پارت های مختلف تمرین و مدل som مشکل ایجاد نشود. در نهایت نیز پنج ردیف اول داده های اصلاح شده و تعداد باقیمانده مقادیر 'unknown' را نمایش دادیم تا از صحت عملیات جایگزینی اطمینان حاصل کنیم.

در خروجی زیر می بینیم که دیگر ستون های حاوی unknown نداریم و تا حد خوبی توانستیم این مشکل مقادیر گمشده را حل کنیم:

```
Unknown values in each column:  
Series([], dtype: int64)
```

سپس در ادامه در خروجی زیر 5 ردیف اول پس از اصلاح مشکل بالا را نمایش می دهیم:

```

      age      job marital education default housing loan contact month \
0  56 housemaid married basic.4y    no    no  no telephone may
1  57   services married high.school    no    no  no telephone may
2  37   services married high.school    no   yes  no telephone may
3  40     admin. married basic.6y    no    no  no telephone may
4  56   services married high.school    no    no yes telephone may

      day_of_week ... campaign pdays previous poutcome emp.var.rate \
0       mon ...        1    999        0 nonexistent      1.1
1       mon ...        1    999        0 nonexistent      1.1
2       mon ...        1    999        0 nonexistent      1.1
3       mon ...        1    999        0 nonexistent      1.1
4       mon ...        1    999        0 nonexistent      1.1

      cons.price.idx cons.conf.idx euribor3m nr.employed y
0      93.994        -36.4      4.857    5191.0  no
1      93.994        -36.4      4.857    5191.0  no
2      93.994        -36.4      4.857    5191.0  no
3      93.994        -36.4      4.857    5191.0  no
4      93.994        -36.4      4.857    5191.0  no

[5 rows x 21 columns]

```

در این مرحله، ستون‌های غیر عددی موجود در دیتاست را شناسایی کردیم تا برای پیش‌پردازش‌های بعدی آماده شوند و این ستون‌ها به صورت زیر هستند:

```
Non-numeric columns: Index(['job', 'marital', 'education', 'default', 'housing', 'loan', 'contact',
   'month', 'day_of_week', 'poutcome', 'y'],
  dtype='object')
```

در ادامه برای حل این مورد نیز ابتدا ستون‌های باینری مثل 'default' و 'y' را با استفاده از LabelEncoder به مقادیر عددی 0 و 1 تبدیل کردیم و سپس برای ستون‌هایی که بیشتر از دو مقدار دارند مثل 'job' و 'education' از کدگذاری One-Hot استفاده کردیم که هر مقدار منحصر به فرد را به یک ستون مجزا با مقادیر 0 یا 1 تبدیل می‌کند. در نهایت نیز پنج ردیف اول را برای بررسی بهتر در خروجی زیر نمایش می‌دهیم:

```

      age default housing loan duration campaign pdays previous \
0    56        0     0   0    261       1    999        0
1    57        0     0   0    149       1    999        0
2    37        0     1   0    226       1    999        0
3    40        0     0   0    151       1    999        0
4    56        0     0   1    307       1    999        0

      emp.var.rate cons.price.idx ... month_oct month_sep day_of_week_mon \
0            1.1      93.994 ...    False    False        True
1            1.1      93.994 ...    False    False        True
2            1.1      93.994 ...    False    False        True
3            1.1      93.994 ...    False    False        True
4            1.1      93.994 ...    False    False        True

      day_of_week_thu day_of_week_tue day_of_week_wed poutcome_nonexistent \
0          False        False        False        True
1          False        False        False        True
2          False        False        False        True
3          False        False        False        True
4          False        False        False        True

      poutcome_success marital_married marital_single
0            False        True        False
1            False        True        False
2            False        True        False
3            False        True        False
4            False        True        False

[5 rows x 48 columns]

```

اگر به شکل بالا دقت کنیم می بینیم که تعداد ستون های ما افزایش پیدا کرده و از 21 به 48 ستون رسیده است. در مرحله بعد با استفاده از روش نرمال سازی Min-Max تمام مقادیر را در بازه 0 تا 1 قرار دادیم تا مقیاس ویژگی ها یکسان شود و در ادامه بتوانیم تحلیل های دقیق تر و بهتری داشته باشیم و مجدد نمونه ای از داده ها را در خروجی زیر نمایش دادیم:

```

      age  default  housing  loan  duration  campaign  pdays  previous \
0  0.481481      0.0      0.0    0.0  0.053070      0.0      1.0      0.0
1  0.493827      0.0      0.0    0.0  0.030297      0.0      1.0      0.0
2  0.246914      0.0      1.0    0.0  0.045954      0.0      1.0      0.0
3  0.283951      0.0      0.0    0.0  0.030704      0.0      1.0      0.0
4  0.481481      0.0      0.0    1.0  0.062424      0.0      1.0      0.0

      emp.var.rate  cons.price.idx  ...  month_oct  month_sep  day_of_week_mon \
0          0.9375     0.698753   ...       0.0       0.0           1.0
1          0.9375     0.698753   ...       0.0       0.0           1.0
2          0.9375     0.698753   ...       0.0       0.0           1.0
3          0.9375     0.698753   ...       0.0       0.0           1.0
4          0.9375     0.698753   ...       0.0       0.0           1.0

      day_of_week_thu  day_of_week_tue  day_of_week_wed  poutcome_nonexistent \
0            0.0          0.0          0.0           1.0
1            0.0          0.0          0.0           1.0
2            0.0          0.0          0.0           1.0
3            0.0          0.0          0.0           1.0
4            0.0          0.0          0.0           1.0

      poutcome_success  marital_married  marital_single
0              0.0          1.0          0.0
1              0.0          1.0          0.0
...
3              0.0          1.0          0.0
4              0.0          1.0          0.0

[5 rows x 48 columns]

```

در نهایت هم دیتابست پیش پردازش شده را به دو مجموعه تست و آموزش که به ترتیب 20 درصد و 80 درصد از دیتابست را شامل می‌شوند تقسیم کردیم:

```

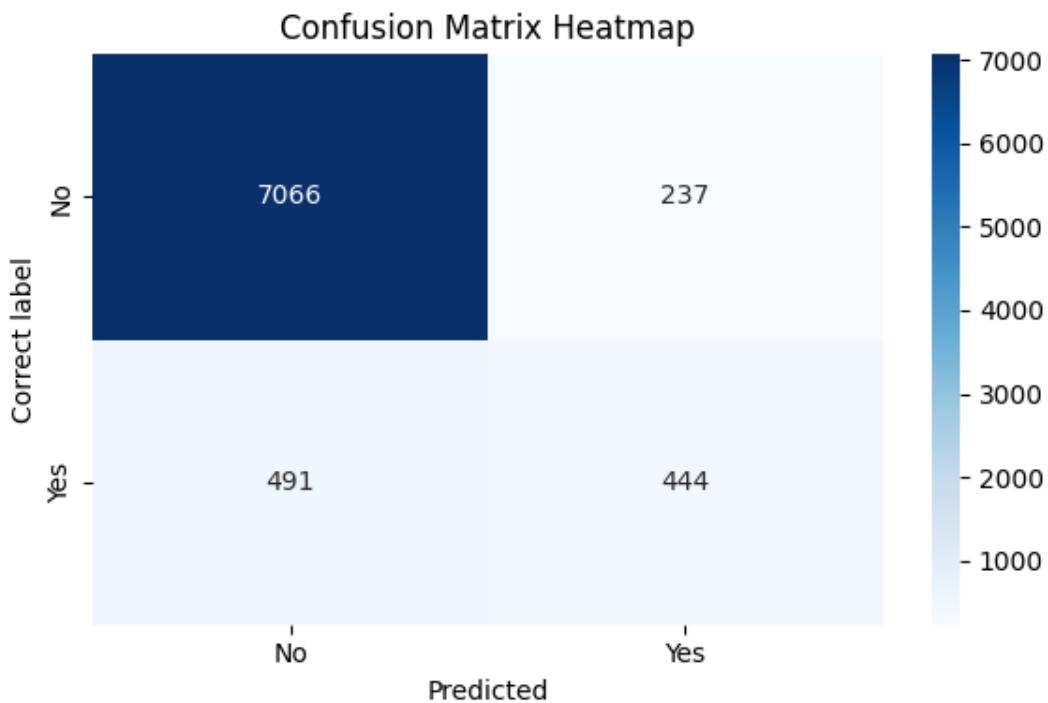
Train shape: (32950, 47)
Test shape: (8238, 47)

```

پس از اینکه پیش پردازش‌های مورد نیاز و همچنین تقسیم داده‌ها را انجام دادیم حال کلاس SOM را پیاده‌سازی کردیم که یک شبکه خودسازمانده کوهونن را شبیه‌سازی می‌کند. ابتدا در تابع `init` پارامترهای اصلی مدل شامل ابعاد شبکه، بعد ورودی، نرخ یادگیری، شعاع همسایگ و تعداد تکرارها را مقداردهی تعریف کردیم؛ سپس با استفاده از تابع `find_bmu`، بهترین واحد تطابق (BMU) را برای هر داده ورودی پیدا می‌کنیم که نزدیک‌ترین نورون به آن داده است. در تابع `neighborhood_func`، میزان تأثیر همسایگ‌ها بر اساس فاصله از BMU و

تکرار فعلی محاسبه می‌شود. در مرحله آموزش نیز وزن‌های شبکه به صورت تدریجی بر اساس داده‌های ورودی وتابع همسایگی به روز می‌شوند و در نهایت توابع visualize و transform به ترتیب برای تبدیل داده‌ها به مختصات BMU و نمایش بصری وزن‌های شبکه استفاده می‌شوند. این پیاده‌سازی امکان کاهش ابعاد و خوشبندی داده‌ها را فراهم می‌کند.

پس از اینکه مدل som را تعریف کردیم قبل از اینکه کاهش بعد به ۸، ۴ و ۲ را انجام دهیم طبق گفته سوال اول آموزش بدون کاهش بعد را انجام می‌دهیم و پس از نمایش نتایج و تجزیه و تحلیل به کاهش بعد با مقادیر گفته شده خواهیم پرداخت. در این مرحله ابتدا مدل Random Forest را آموزش دادیم و زمان اجرای آن را محاسبه کردیم. سپس با استفاده از داده‌های آزمون، پیش‌بینی‌های مدل را انجام دادیم و معیارهای ارزیابی مختلف شامل دقیق (Accuracy)، Adjusted Rand Index (ARI) و Silhouette Score را محاسبه نمودیم و در نهایت نیز ماتریس درهم ریختگی (Confusion Matrix) را رسم کردیم تا عملکرد مدل در پیش‌بینی کلاس‌های مختلف را به صورت بصری نمایش دهیم. این معیارها به ما کمک می‌کنند تا کیفیت مدل را از جنبه‌های مختلف ارزیابی کنیم. همان‌طور که ماتریس زیر می‌بینیم 7066 تا از کلاس NO را به درستی تشخیص داده است و همچنین 444 تا از کلاس‌های Yes را درست تشخیص داده است و مثل فرمول‌های تمرین‌های گذشته به کمک مقادیر ماتریس می‌توانیم مقدار دقیق ... را نیز بدست آوریم:

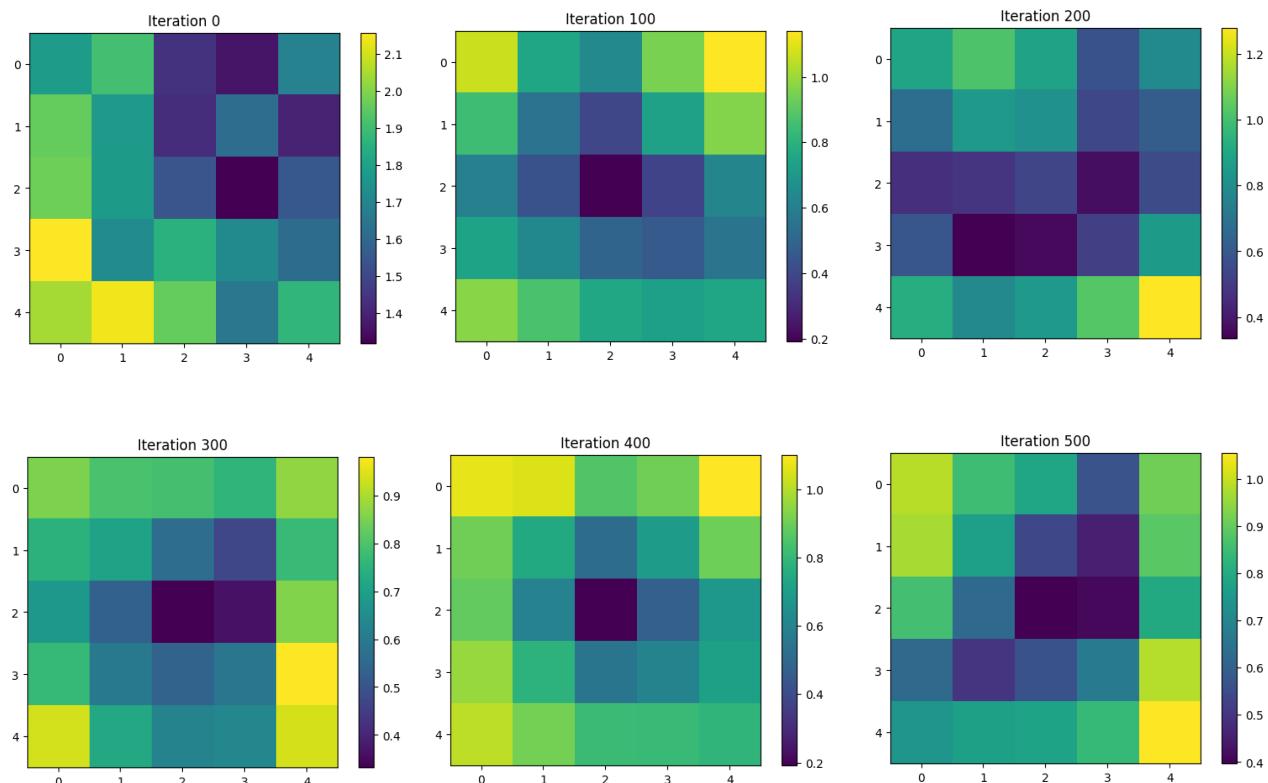


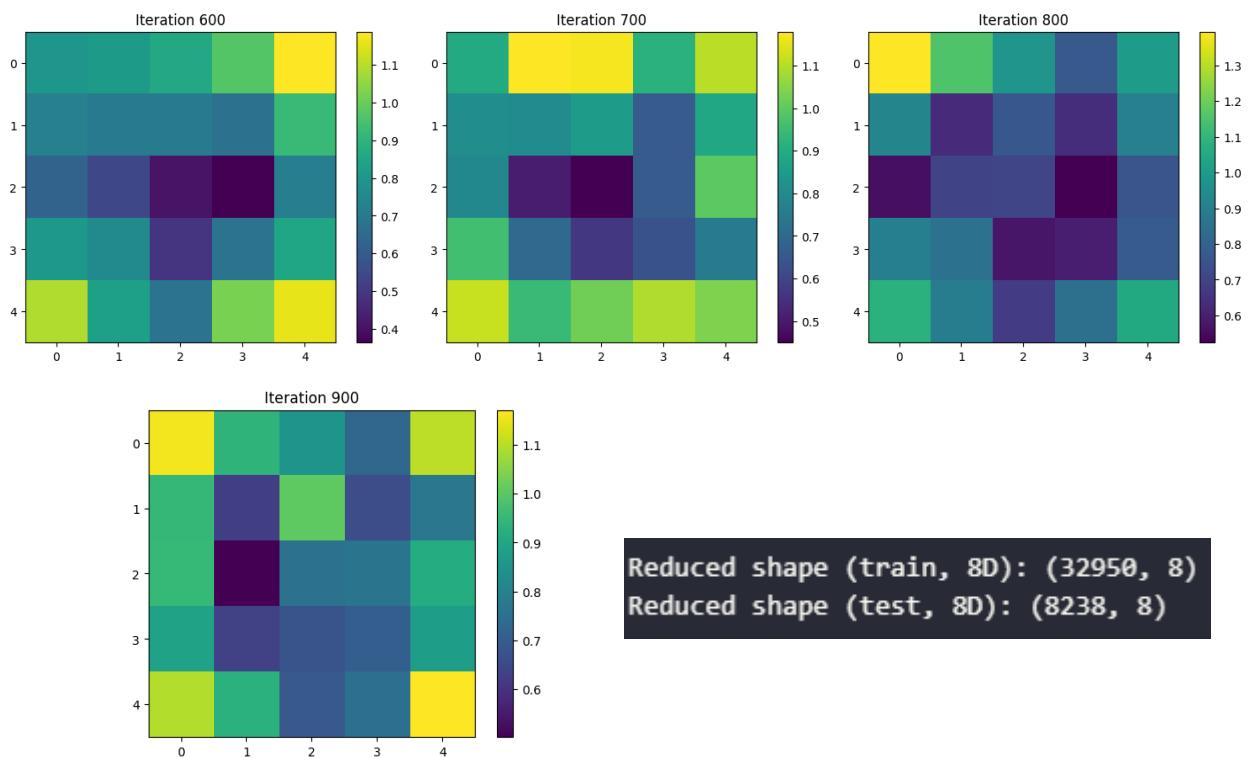
در شکل پایین نیز سایر معیارها را داریم و می‌بینیم این مدل در مدت زمان نسبتاً کوتاه آموزش دیده و به دقیق قبول ۹۱.۰۱۶٪ پیش‌بینی نتایج دست یافته است که نشان‌دهنده عملکرد خوب مدل در طبقه‌بندی داده‌هاست. مقدار ARI حاکی از آن است که مدل تا حدی توانسته ساختار خوشبندی داده را شناسایی کند و از طرف پایین نشان می‌دهد که خوشبندی انجام‌شده چندان متمایز نیست و احتمالاً همپوشانی Silhouette Score

قابل توجهی بین خوشها وجود دارد. به طور کلی می توانیم بگوییم مدل در طبقه بندی عملکرد خوبی داشته ولی در خوشبندی داده ها چندان متمایز عمل نکرده است:

```
Training Time: 5.5987 seconds
Accuracy: 0.9116
Adjusted Rand Index (ARI): 0.4479
Silhouette Score: 0.0756
```

در ادامه بر می گردیم به کاهش بعد با استفاده از som و در این بخش، ابتدا یک شبکه خودسازمانده (SOM) با ابعاد 5×5 نورون آموزش دادیم تا الگوهای موجود در داده ها را شناسایی کند. سپس با محاسبه فاصله هر داده تا نزدیک ترین نورون های شبکه، داده های اصلی را به بردارهای 8 بعدی جدید تبدیل کردیم که نمایانگر موقعیت داده ها در فضای نقشه SOM هستند. این تبدیل باعث کاهش ابعاد داده ها شد، در حالی که اطلاعات مکانی و ساختاری آن ها حفظ گردید. در نهایت نیز خروجی این بخش را در خروجی نمایش می دهیم:



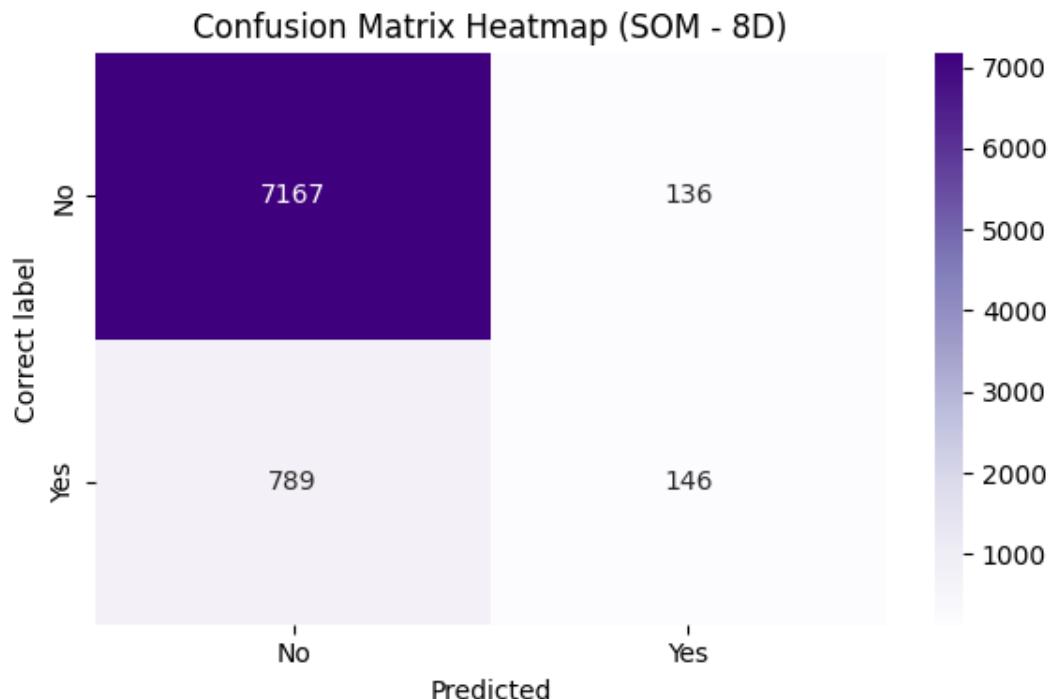


در ادامه یک مدل Random Forest روی داده‌های کاهش یافته ۸ بعدی آموزش دادیم و زمان اجرای آن را ثبت کردیم. سپس با استفاده از داده‌های آزمون، پیش‌بینی‌های مدل را انجام دادیم و معیارهای ارزیابی مختلف را محاسبه نمودیم و در نهایت نیز ماتریس درهم ریختگی را رسم کردیم تا عملکرد مدل در پیش‌بینی کلاس‌های مختلف را به صورت بصری نمایش دهیم.

در شکل زیر مشاهده می‌کنیم که پس از کاهش ابعاد به ۸ بعد با SOM، در مدت زمان حدوداً ۱۹ ثانیه آموزش دیده و به دقت ۸۸.۷۷٪ در پیش‌بینی نتایج دست یافته است که نشان‌دهنده عملکرد نسبتاً خوب مدل در طبقه‌بندی داده‌هاست، هرچند نسبت به حالت قبل کاهش دقت مشاهده می‌شود. مقدار ARI نیز حاکی از همبستگی نسبتاً قوی بین خوش‌بندی انجام‌شده و ساختار واقعی داده‌هاست. از سوی دیگر، Silhouette Score نیز نشان‌دهنده بهبود قابل توجهی در تمایز خوش‌ها نسبت به مرحله قبل است و اگرچه هنوز فضای برای بهبود وجود دارد. به طور کلی می‌توان گفت کاهش ابعاد با SOM منجر به حفظ ساختار داده‌ها شده و مدل توانسته هم در طبقه‌بندی و هم در خوش‌بندی عملکرد مناسبی ارائه دهد، هرچند این کاهش ابعاد باعث افت جزئی در دقت طبقه‌بندی شده است:

```
[SOM with 8 dimensions]
Training Time: 19.1805 seconds
Accuracy: 0.8877
Adjusted Rand Index (ARI): 0.8877
Silhouette Score: 0.5223243381340082
```

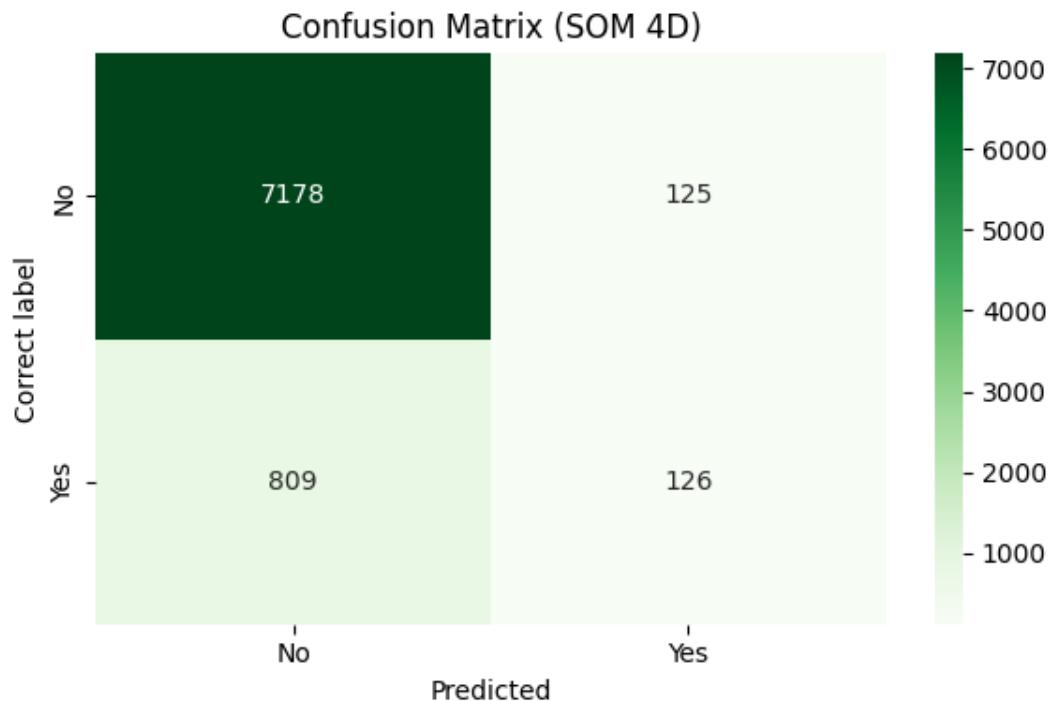
در ماتریس زیر می بینیم 7167 تا از کلاس NO را به درستی تشخیص داده است و همچنین 146 تا از کلاس های Yes را درست تشخیص داده است و مثل فرمول های تمرين های گذشته به راحتی می توانیم که به کمک مقادیر ماتریس می توانیم مقدار دقت و ... را نیز بدست آوریم:



در ادامه، همان مراحل قبلی را این بار برای کاهش ابعاد به 4 بعد تکرار کردیم. ابتدا داده ها را با SOM به فضای 4 بعدی تبدیل نمودیم، سپس یک مدل Random Forest روی این داده های کاهش یافته آموزش دادیم و در نهایت عملکرد مدل را با معیارهای مختلف ارزیابی و نتایج را تحلیل کردیم. همان طور که در خروجی زیر می بینیم، نتایج نشان می دهند مدل پس از کاهش ابعاد به 4 بعد، در مدت زمان حدودا 21 ثانیه آموزش دیده و به دقت 88.66% دست یافته که عملکردی تقریبا مشابه حالت 8 بعدی دارد. مقدار ARI نیز همبستگی ضعیفتر بین خوشبندی و ساختار واقعی داده نسبت به مرحله قبل را نشان می دهد، در حالی که مقدار Silhouette Score حاکی از کیفیت نسبتاً مناسب اما نه چندان مطلوب در تمايز خوشبندی هاست. به طور کلی، کاهش بیشتر ابعاد اگرچه تأثیر محسوسی بر دقت طبقه بندی نداشته اما باعث کاهش کیفیت خوشبندی شده است:

[SOM with 4 dimensions]
 Training Time: 21.6311 s
 Accuracy: 0.8866
 ARI: 0.1500
 Silhouette: 0.4918652146844992

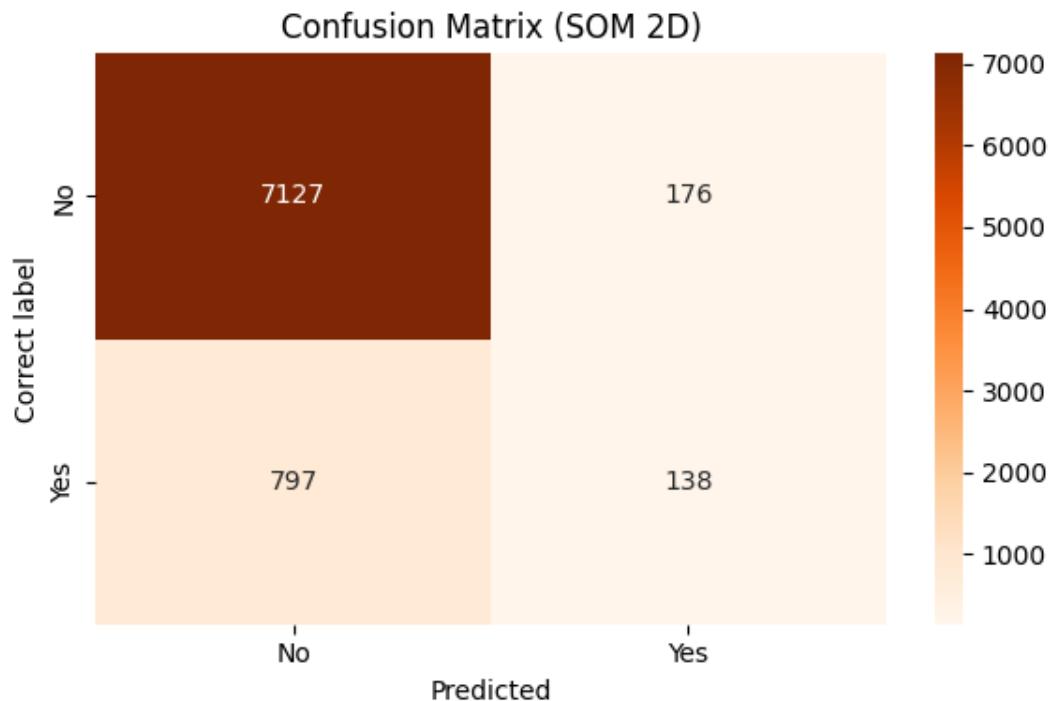
ماتریس زیر را نیز مثل موارد قبلی مجدد می‌توانیم تجزیه و تحلیل کنیم و می‌بینیم که 7178 تا از کلاس NO را به درستی تشخیص داده است و همچنین 126 تا از کلاس‌های Yes را درست تشخیص داده است و مثل فرمول‌های تمرین‌های گذشته به راحتی می‌توانیم که به کمک مقادیر ماتریس می‌توانیم مقدار دقیق و ... را نیز بدست آوریم:



در ادامه، همان مراحل قبلی را این بار برای کاهش ابعاد به 4 بعد تکرار کردیم. ابتدا داده‌ها را با SOM به فضای 4 بعدی تبدیل نمودیم، سپس یک مدل Random Forest روی این داده‌های کاهش یافته آموزش دادیم و در نهایت عملکرد مدل را با معیارهای مختلف ارزیابی و نتایج را تحلیل کردیم. شکل خروجی زیر نیز نتایج کاهش ابعاد به 2 بعد نشان می‌دهد و مدل در زمان کوتاه‌تر و در حدود 13 ثانیه آموزش دیده و به دقت 88.19% رسیده که کاهش جزئی نسبت به مراحل قبل دارد. مقدار ARI نیز نشان می‌دهد مدل همچنان تا حدی توانسته ساختار خوشه‌های واقعی را شناسایی کند. مقدار Silhouette Score که نسبت به مراحل قبل کاهش یافته، حاکی از کاهش کیفیت و تمایز خوشه‌ها در فضای 2 بعدی است. این نتایج نشان می‌دهد هرچه ابعاد را بیشتر کاهش دهیم، اگرچه زمان آموزش کمتر می‌شود اما ممکن است به کیفیت خوشه‌بندی لطمه بخورد، در حالی که دقت طبقه‌بندی تغییر محسوسی نمی‌کند. به طور کلی مدل در فضای 2 بعدی هم عملکرد قابل قبولی در طبقه‌بندی دارد اما برای کاربردهای حساس به خوشه‌بندی ممکن است نیاز به ابعاد بالاتری داشته باشیم.

[SOM with 2 dimensions]
Training Time: 13.5843 s
Accuracy: 0.8819
ARI: 0.1499
Silhouette: 0.44640699260924427

ماتریس زیر را نیز مثل موارد قبلی مجدد می‌توانیم تجزیه و تحلیل کنیم و می‌بینیم که 7127 تا از کلاس NO را به درستی تشخیص داده است و همچنان 138 تا از کلاس‌های Yes را درست تشخیص داده است و مثل فرمول‌های تمرین‌های گذشته به راحتی می‌توانیم که به کمک مقادیر ماتریس می‌توانیم مقدار دقต و ... را نیز بدست آوریم:

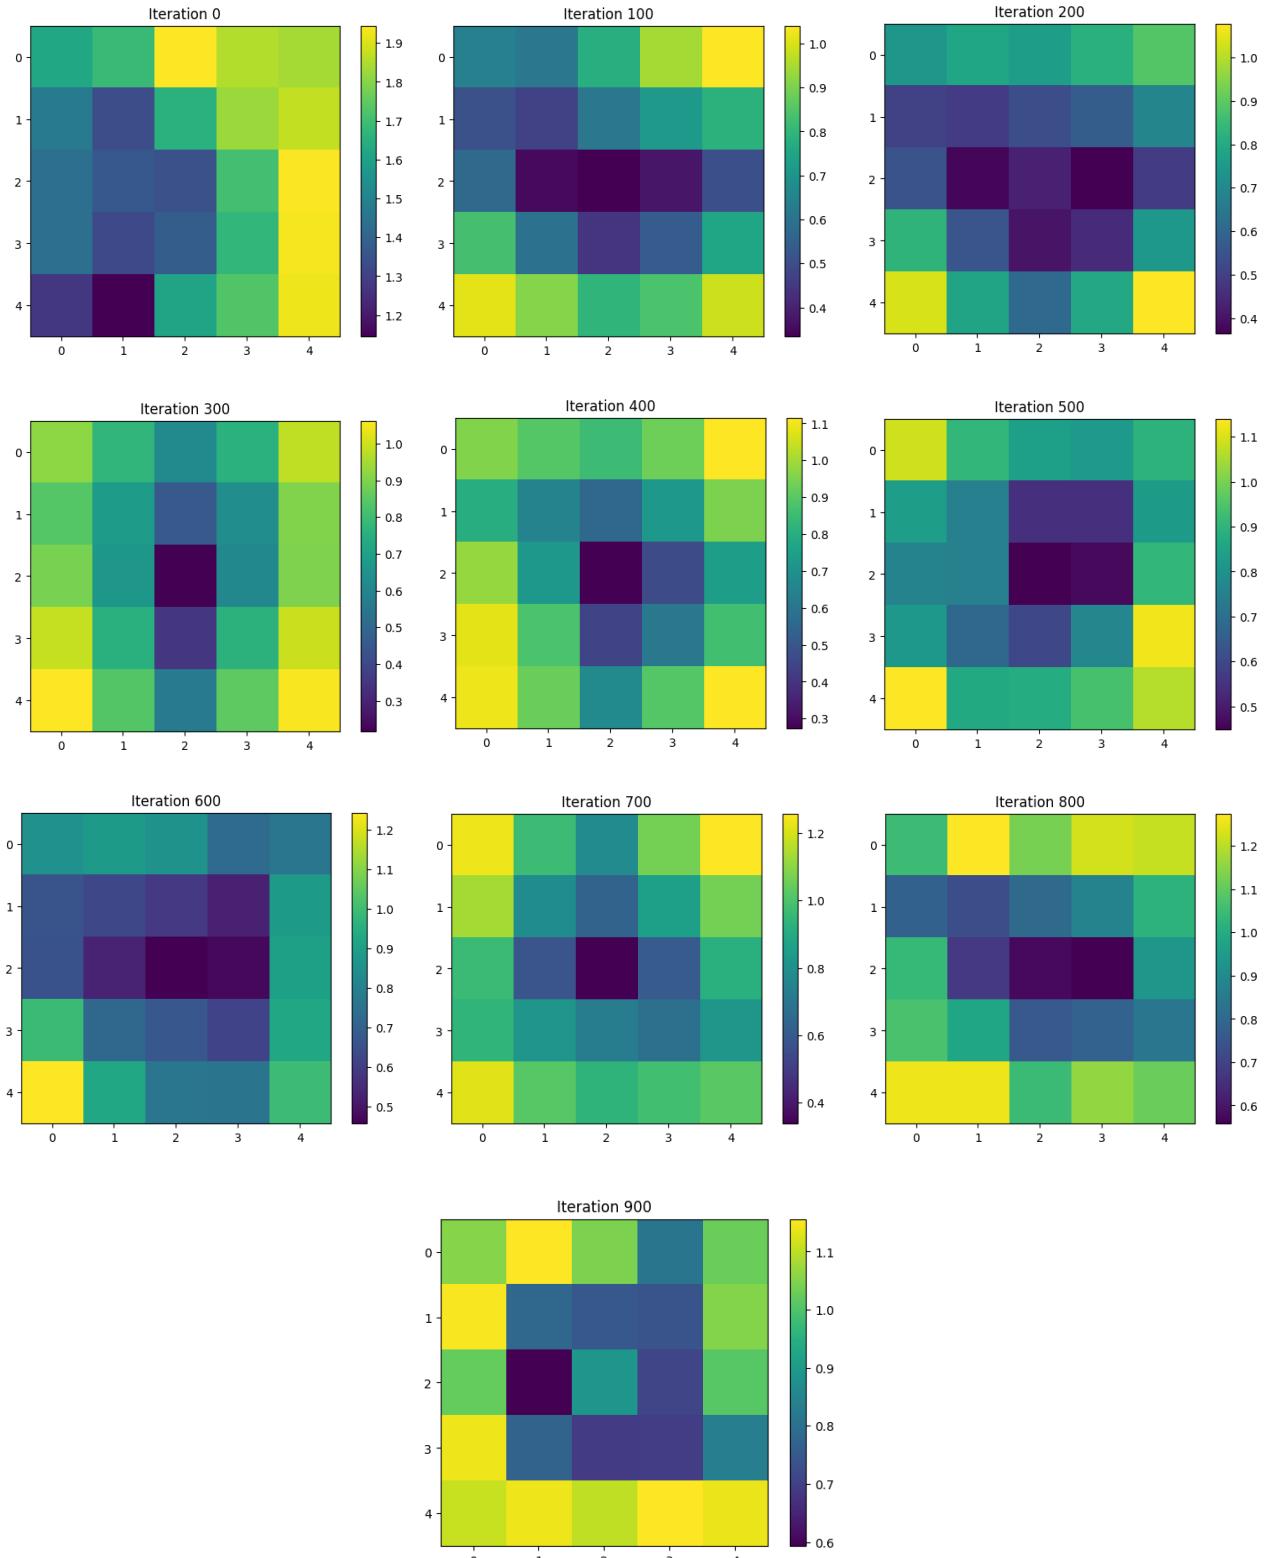


از تحلیل‌های بالا به این نتیجه رسیدیم که آموزش دسته‌بند بدون کاهش بعد دقت حدود 91% درصد داشت و با کاهش بعد به 8 دقت به حدود 88% رسید و با ادامه کاهش بعد به 4 و 2 این دقت به صورت جزئی کاهش داشت و همینطور زمان آموزش مدل هم با کاهش بعد کمتر شد و هرجه به سمت بعد 2 پیش رفتیم مدل به مدت زمان کمتری برای آموزش نیاز پیدا کرد اما از آن طرف کیفیت خوش بندی کاهش پیدا کرد و طبق توضیحاتی که قسمت‌های قبلی دادیم یک تریدآفی داریم و در کل کاهش بعد به ابعاد گفته شده مدل عملکرد خوبی از خود نشان داد و دقت هر سه مدل حدود 88% شد.

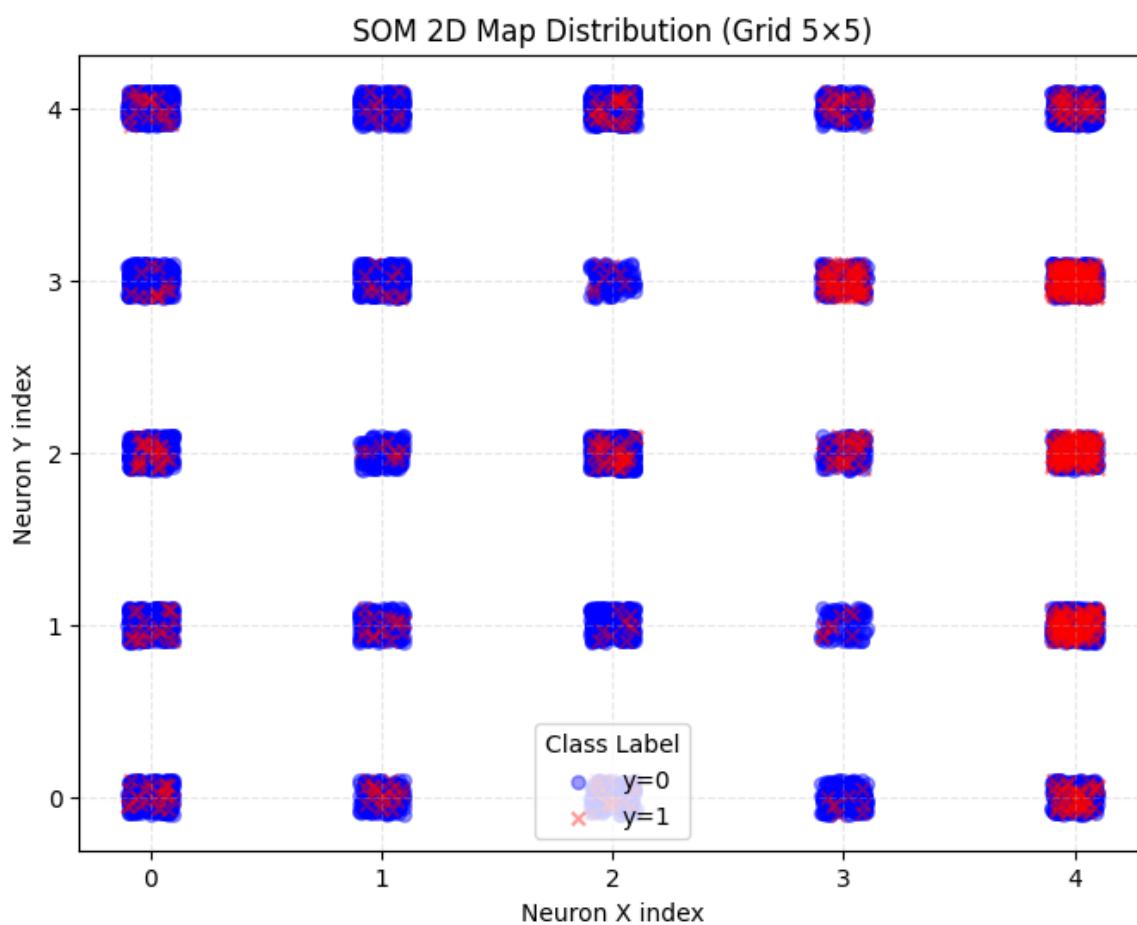
2

در این پارت باید با استفاده از شبکه SOM یک نقشه 2 بعدی از توزیع داده‌ها ایجاد می‌کنیم تا الگوهای پنهان و ساختار کلی داده‌ها را بصری‌سازی کنیم. ابتدا شبکه SOM با ابعاد 5×5 نورون آموزش دادیم تا ساختار داده‌ها را یاد بگیرد. سپس برای هر نمونه از داده‌های آزمون، بهترین نورون تطبیق یافته (BMU) را در نقشه SOM پیدا کردیم و مختصات آن‌ها را استخراج نمودیم. برای بهبود نمایش بصری، مقدار کمی نویز تصادفی به مختصات

اضافه کردیم تا از همپوشانی نقاط جلوگیری شود و در نهایت نیز با رسم نقاط بر اساس لیبل‌های واقعی توزیع داده‌ها را روی نقشه SOM بصری‌سازی کردیم و به ازای هر 100 تکرار در خروجی داریم:



در این نقشه‌ی ۲ بعدی SOM با ساختار 5×5 ، داده‌های مربوط به دو کلاس $y=0$ و $y=1$ پس از کاهش بعد به صورت خوش‌هایی پیرامون نورون‌های شبکه پخش شده‌اند. هر نورون در این شبکه نقش یک مرکز تجمع برای داده‌هایی با ویژگی‌های مشابه را دارد. مشاهده می‌شود که نمونه‌های هر دو کلاس در اکثر نورون‌ها حضور دارند اما در برخی نقاط تراکم یکی از کلاس‌ها بیشتر است که بیانگر تمايل داده‌های آن کلاس به ویژگی‌های خاص آن نورون می‌باشد (در بعضی نورون‌ها دایره‌های آبی که نشانگر کلاس ۰ هستند زیاد هستند و در بعضی دیگر از نورون‌ها که در شکل زیر هم می‌بینیم ضریبرهای قرمز که همان کلاس ۱ هستند بیشتر دیده می‌شوند). این توزیع نشان می‌دهد که ویژگی‌های دو کلاس در بعضی ابعاد همپوشانی دارند اما در برخی نواحی، SOM موفق شده آن‌ها را از هم تفکیک کند. در مجموع این شبکه خودسازمانده ما توانسته ساختار درونی داده‌ها و شباهت‌های نسبی بین کلاس‌ها را در قالب یک نمای فشرده و قابل تحلیل حفظ کند و تحلیل‌های انجام شده در بالا را می‌توانیم در شکل زیر نیز به طور کامل مشاهده کنیم:



3

در این پارت باید تأثیر پارامترهای کلیدی SOM شامل اندازه شبکه، نرخ یادگیری و تعداد تکرارهای آموزش را بر کیفیت کاهش ابعاد بررسی کنیم. برای این کار، مقادیر مختلفی برای هر پارامتر تست شده و نتایج حاصل از نظر معیارهای ارزیابی (مانند دقت طبقه‌بندی و کیفیت خوش‌بندی) با استفاده از نموذارها یا جداول مقایسه‌ای تحلیل وارائه می‌شود. ابتدا سایز شبکه را 5×5 در نظر گرفتیم و پارامترهای دیگر را تغییر دادیم و تأثیر را در ادامه بررسی می‌کنیم. در تست اول مقدار نرخ یادگیری 0.5 و تعداد تکرار 1000 را اجرا کردیم که خروجی زیر حاصل شد:

```
[Grid 5x5]
Accuracy: 0.8858
ARI:      0.1787
Silhouette: 0.5420
Training Time: 18.1099 seconds
```

در تست دوم مقدار نرخ یادگیری را تغییر دادیم و برابر 0.1 قرار دادیم و با تعداد تکرار 1000 را اجرا کردیم که خروجی زیر حاصل شد:

```
[Grid 5x5]
Accuracy: 0.8877
ARI:      0.1847
Silhouette: 0.5014
Training Time: 19.7897 seconds
```

در تست سوم مقدار نرخ یادگیری 0.5 و تعداد تکرار را به 500 کاهش دادیم و اجرا کردیم که خروجی زیر حاصل شد:

```
[Grid 5x5]
Accuracy: 0.8869
ARI:      0.1565
Silhouette: 0.3407
Training Time: 21.1132 seconds
```

در تست سوم مقدار نرخ یادگیری 0.5 و تعداد تکرار را به 2000 افزایش دادیم و اجرا کردیم که خروجی زیر حاصل شد:

[Grid 5x5]
Accuracy: 0.8864
ARI: 0.1684
Silhouette: 0.5009
Training Time: 23.6451 seconds

سپس آمدیم برای تجزیه و تحلیل بهتر خروجی‌های بالا که برای یک شبکه 5x5 بود را در جدول زیر نمایش دادیم و تحلیل نتایج نشان‌دهنده تأثیر متفاوت تنظیم پارامترهای SOM بر عملکرد مدل است. بهترین ترکیب پارامتری در این آزمایش‌ها، نرخ یادگیری 0.1 با 1000 تکرار بوده که بالاترین مقدار ARI و دقت را به همراه Silhouette Score نسبتاً خوب ارائه داده است. کاهش تعداد تکرارها به 500 موجب افت محسوس کیفیت خوش‌بندی شده و دقت را هم جزئی کاهش داده است در حالی که افزایش آن به 2000 بهبود قابل توجهی ایجاد نکرده و تنها زمان آموزش را افزایش داده است. نرخ یادگیری 0.5 نیز نتایج نسبتاً مطلوبی داشته اما نسخه 0.1 آن عملکرد کمی بهتر نشان داده است (در صورت افزایش نرخ یادگیری تا 1 احتمال کاهش دقت و ... به خاطر نرخ بالا و آموزش نامطلوب بیشتر می‌شود). جالب توجه اینکه تغییرات پارامترها تأثیر محدودی بر دقت نهایی مدل داشته و این مقدار در تمام آزمایش‌ها حول 88% نوسان داشته است که نشان‌دهنده پایداری نسبی مدل در برابر تغییر پارامترهاست. موارد گفته شده را در جدول زیر می‌توانیم ببینیم:

5x5	5x5	5x5	5x5	اندازه شبکه
0.5	0.5	0.1	0.5	نرخ یادگیری
2000	500	1000	1000	تعداد تکرار
%16.84	%15.65	%18.47	%17.87	ARI
%50.09	%34.07	%50.14	%54.2	Silhouette Score
23.64 s	21.11 s	19.78 s	18.1 s	Training Time
%88.64	%88.69	%88.77	%88.58	دقت نهایی

در ادامه سایز شبکه را 10x10 در نظر گرفتیم و پارامترهای دیگر را تغییر دادیم و تأثیر را در ادامه بررسی می‌کنیم. در تست اول مقدار نرخ یادگیری 0.5 و تعداد تکرار 1000 را اجرا کردیم که خروجی زیر حاصل شد:

```
[Grid 10x10]
Accuracy: 0.8874
ARI: 0.1615
Silhouette: 0.4136
Training Time: 22.0060 seconds
```

در تست دوم مقدار نرخ یادگیری را تغییر دادیم و برابر 0.1 قرار دادیم و با تعداد تکرار 1000 را اجرا کردیم که خروجی زیر حاصل شد:

```
[Grid 10x10]
Accuracy: 0.8837
ARI: 0.1147
Silhouette: 0.3679
Training Time: 20.3869 seconds
```

در تست سوم مقدار نرخ یادگیری 0.5 و تعداد تکرار را به 500 کاهش دادیم و اجرا کردیم که خروجی زیر حاصل شد:

```
[Grid 10x10]
Accuracy: 0.8859
ARI: 0.1569
Silhouette: 0.4621
Training Time: 22.2125 seconds
```

در تست سوم مقدار نرخ یادگیری 0.5 و تعداد تکرار را به 2000 افزایش دادیم و اجرا کردیم که خروجی زیر حاصل شد:

[Grid 10x10]
Accuracy: 0.8883
ARI: 0.1790
Silhouette: 0.4761
Training Time: 20.7746 seconds

سپس آمدیم برای تجزیه و تحلیل بهتر خروجی‌های بالا که برای یک شبکه 10×10 بود را در جدول زیر نمایش دادیم و تحلیل نتایج نشان‌دهنده تأثیر متفاوت تنظیم پارامترهای SOM بر عملکرد مدل است. تحلیل نتایج جدول برای شبکه‌ی 10×10 نشان‌دهنده‌ی برعی تفاوت‌ها نسبت به شبکه‌ی 5×5 است. در این تنظیمات، افزایش اندازه‌ی شبکه به 10×10 موجب کاهش نسبی مقادیر ARI در مقایسه با شبکه‌ی کوچک‌تر شده است، به‌طوری‌که بهترین مقدار ARI با 2000 تکرار و نرخ یادگیری 0.5 به‌دست آمده که نسبت به حالت 5×5 بهبود جزئی نشان می‌دهد. نکته‌ی قابل توجه این است که Silhouette Score در این اندازه‌ی شبکه بهبود یافته و به 47.61٪ رسیده است که نشان‌گر تمایز خوب خوش‌های در فضای با شبکه‌ی کوچک‌تر است. با این حال، نرخ یادگیری 0.01 در این شبکه نتایج ضعیفتری را در مقایسه با شبکه‌ی کوچک‌تر نشان داده و ARI را کاهش داده است. در مقابل کاهش تعداد تکرارها به 500 تأثیر محسوسی بر کیفیت خوش‌بندی نداشته است؛ زمان آموزش نیز در این شبکه تقریباً ثابت بوده که نشان‌دهنده‌ی کارایی مناسب مدل حتی در ابعاد بزرگ‌تر است. دقت نهایی مدل در تمام آزمایش‌ها حول 88٪ ثابت مانده که مجدداً تأیید می‌کند تغییر پارامترها تأثیر چندانی بر دقت طبقه‌بندی ندارد. به‌نظر می‌رسد افزایش اندازه‌ی شبکه اگرچه می‌تواند کیفیت خوش‌بندی را بهبود بخشد، اما لزوماً منجر به افزایش تطابق با برجسب‌های واقعی (ARI) نمی‌شود و انتخاب اندازه‌ی شبکه باید با توجه به هدف تحلیل (خوش‌بندی یا طبقه‌بندی) صورت گیرد. موارد گفته شده را در جدول زیر می‌توانیم ببینیم:

10x10	10x10	10x10	10x10	اندازه شبکه
0.5	0.5	0.1	0.5	نرخ یادگیری
2000	500	1000	1000	تعداد تکرار
%17.9	%15.69	%11.47	%16.15	ARI
%47.61	%46.21	%36.79	%41.36	Silhouette Score
20.77 s	22.21 s	20.38 s	22.00 s	Training Time
%88.83	%88.59	%88.37	%88.74	دقت نهایی

در نهایت نیز سایز شبکه را 15×15 در نظر گرفتیم و پارامترهای دیگر را تغییر دادیم و تاثیر را در ادامه بررسی می‌کنیم. در تست اول مقدار نرخ یادگیری 0.5 و تعداد تکرار 1000 را اجرا کردیم که خروجی زیر حاصل شد:

```
[Grid 15x15]
Accuracy: 0.8888
ARI: 0.1748
Silhouette: 0.4362
Training Time: 19.2706 seconds
```

در تست دوم مقدار نرخ یادگیری را تغییر دادیم و برابر 0.1 قرار دادیم و با تعداد تکرار 1000 را اجرا کردیم که خروجی زیر حاصل شد:

```
[Grid 15x15]
Accuracy: 0.8874
ARI: 0.1615
Silhouette: 0.4584
Training Time: 23.2587 seconds
```

در تست سوم مقدار نرخ یادگیری 0.5 و تعداد تکرار را به 500 کاهش دادیم و اجرا کردیم که خروجی زیر حاصل شد:

```
[Grid 15x15]
Accuracy: 0.8846
ARI: 0.0939
Silhouette: 0.3123
Training Time: 23.3029 seconds
```

در تست سوم مقدار نرخ یادگیری 0.5 و تعداد تکرار را به 2000 افزایش دادیم و اجرا کردیم که خروجی زیر حاصل شد:

```
[Grid 15x15]
Accuracy: 0.8853
ARI: 0.1388
Silhouette: 0.3432
Training Time: 17.8907 seconds
```

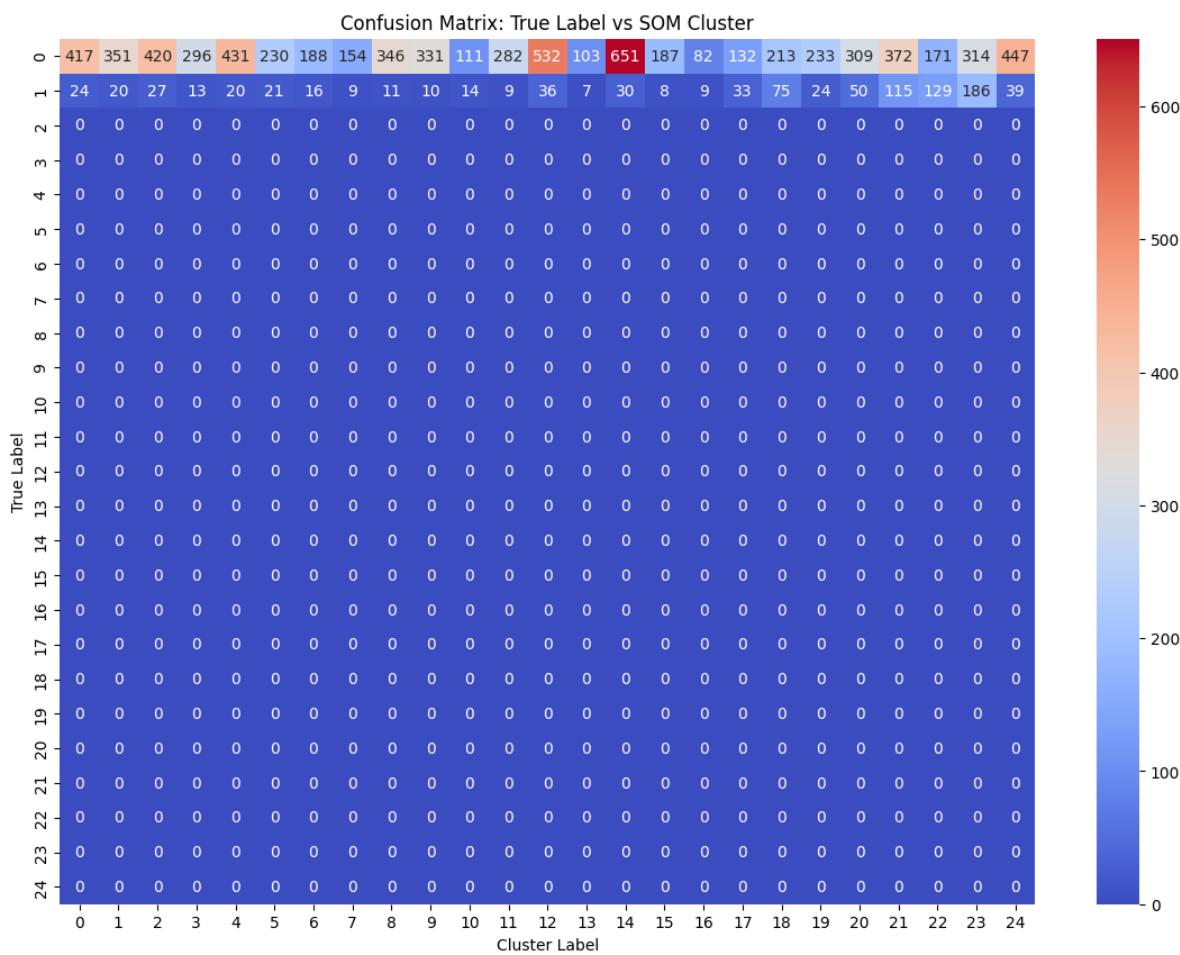
سیس آمدیم برای تجزیه و تحلیل بهتر خروجی‌های بالا که برای یک شبکه 10×10 بود را در جدول زیر نمایش دادیم و تحلیل نتایج نشان‌دهنده تأثیر متفاوت تنظیم پارامترهای SOM بر عملکرد مدل است.

تحلیل نتایج شبکه 15×15 نشان‌دهنده رفتار پیچیده‌تر و جالب‌تری نسبت به اندازه‌های کوچک‌تر است. در این بعد بزرگ‌تر شبکه، بهترین عملکرد از نظر ($\% 17.48$) ARI با نرخ یادگیری ۰.۵ و ۱۰۰۰ تکرار حاصل شده که نسبت به شبکه‌های 5×5 و 10×10 بهبود محسوسی را نشان می‌دهد؛ با این حال نتایج نشان می‌دهد افزایش تعداد تکرارها به ۲۰۰۰ برخلاف انتظار منجر به کاهش ARI به $\% 13.88$ شده که احتمالاً نشان‌دهنده پدیده بیش‌برازش در ابعاد بزرگ شبکه است. از سوی دیگر، کاهش تعداد تکرارها به ۵۰۰ موجب افت شدید هر دو معیار خوشبندی شده که حساسیت بالای این ابعاد شبکه به تعداد تکرارهای آموزش را آشکار می‌سازد، همچنین زمان آموزش در این شبکه بین ۱۷ تا ۲۳ ثانیه متغیر بوده است. همانند آزمایش‌های قبلی، دقت نهایی مدل حول $\% 88$ ثابت مانده که نشان‌دهنده استحکام و پایداری مدل در برابر تغییر ابعاد شبکه است. در مجموع، شبکه 15×15 در برخی تنظیمات خاص (نرخ یادگیری ۰.۵ با ۱۰۰۰ تکرار) بهترین مقادیر ARI را در بین تمام اندازه‌های آزمایش شده ارائه داده است، اما ناپایداری نتایج در سایر تنظیمات نشان می‌دهد که کار با این ابعاد بزرگ نیازمند تنظیم دقیق‌تر پارامترهایست. این مشاهدات بر اهمیت تعادل دقیق بین اندازه شبکه و پارامترهای آموزشی تأکید دارد و نشان می‌دهد که انتخاب بهینه این پارامترها باید با توجه به هدف نهایی تحلیل (خوشبندی دقیق یا طبقه‌بندی پایدار) و با در نظر گرفتن منابع محاسباتی موجود باید انجام پذیرد. موارد گفته شده را در جدول زیر می‌توانیم ببینیم:

15×15	15×15	15×15	15×15	اندازه شبکه
۰.۵	۰.۵	۰.۱	۰.۵	نرخ یادگیری
۲۰۰۰	۵۰۰	۱۰۰۰	۱۰۰۰	تعداد تکرار
$\% 13.88$	$\% 9.39$	$\% 16.15$	$\% 17.48$	ARI
$\% 34.32$	$\% 31.23$	$\% 45.84$	$\% 43.62$	Silhouette Score
۱۷.۸۹ s	۲۳.۳۰ s	۲۳.۲۵ s	۱۹.۲۷ s	Training Time
$\% 88.53$	$\% 88.46$	$\% 88.74$	$\% 88.88$	دقت نهایی

.4

در این بخش باید از شبکه خودسازمانده برای خوشبندی داده‌ها بدون استفاده از برجسب‌ها استفاده کنیم، سپس خوشبندی ایجاد شده را با برجسب‌های واقعی مقایسه کرده و کیفیت خوشبندی را با معیارهای ارزیابی تحلیل نماییم. ابتدا با استفاده از SOM داده‌های تست را به خوشبندی اختصاص دادیم. برای این کار، ابتدا بهترین نورون‌های تطبیق‌یافته (BMU) برای هر نمونه را یافت و سپس با ترکیب مختصات آن‌ها در شبکه SOM، برجسب‌های خوش را ایجاد کردیم. در مرحله بعد نیز کیفیت خوشبندی را با معیارهای Silhouette و ARI و Score بررسی کردیم. در نهایت نیز ماتریس درهم ریختگی را رسم کردیم که ارتباط بین برجسب‌های واقعی و برجسب‌های خوش را به صورت بصری نمایش می‌دهد:



در این خروجی، شبکه SOM داده‌ها را به صورت بدون نظارت خوشبندی کرده است و نتایج در قالب یک ماتریس درهم ریختگی نمایش داده شده‌اند. همان‌طور که مشاهده می‌شود تنها ردیف‌های ۰ و ۱ دارای مقادیر غیر صفر هستند، در حالی که سایر ردیف‌ها کاملاً صفر باقی مانده‌اند. این نشان می‌دهد که کل داده‌ها فقط شامل دو کلاس (افتاح حساب یا عدم افتتاح حساب) بوده‌اند و هیچ داده‌ای با برجسب‌های دیگر در مجموعه وجود

نداشته است. به طور کلی این نتایج نشان می‌دهند که SOM توانسته ساختار پنهان داده‌ها را تا حد مناسبی یاد بگیرد اما همچنان مقداری همپوشانی و پراکندگی در خوشبندی وجود دارد.

در شکل زیر نیز نتایج نشان می‌دهند که خوشبندی انجام شده توسط SOM بدون استفاده از برچسب‌ها، ارتباط ضعیفی با ساختار واقعی داده‌ها دارد؛ همچنین مقدار پایین Silhouette Score حاکی از آن است که خوشبندی ایجاد شده فاقد ساختار درونی متمایز هستند و نقاط به خوبی از هم تفکیک نشده‌اند. این نتایج نشان می‌دهد که در این تنظیمات نتوانسته الگوی معناداری در داده‌ها شناسایی کند که ممکن است به دلیل پیچیدگی ذاتی توزیع داده‌ها باشد:

```
Unsupervised Clustering with SOM:  
Adjusted Rand Index (ARI): 0.0033  
Silhouette Score: 0.04069527781048046
```

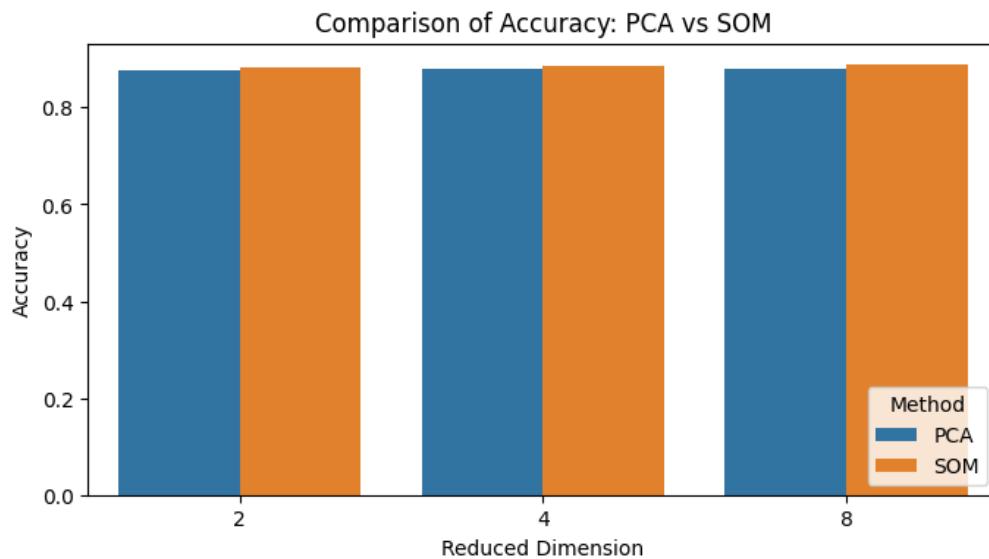
5

در این مرحله باید عملکرد شبکه خودسازمانده را با روش‌های مرسوم کاهش ابعاد مثل PCA یا t-SNE مقایسه کنیم. در این بخش ابتدا یک فرآیند سیستماتیک برای مقایسه دو روش کاهش ابعاد PCA و SOM طراحی کردیم. برای این کار، داده‌های آموزشی و آزمون را به ابعاد مختلف کاهش دادیم و سپس یک مدل Random Forest روی داده‌های کاهش‌یافته آموزش دادیم. در ادامه، معیارهای ارزیابی مختلف که در بخش‌های قبل با آنها کار کردیم و آشناییت داریم را برای هر حالت محاسبه و ذخیره کردیم. در نهایت نیز نتایج حاصل را در خروجی زیر نمایش دادیم:

	method	dim	train_time	accuracy	ari	silhouette
0	PCA	8	21.210346	0.879340	0.194945	0.041123
1	PCA	4	22.911953	0.879097	0.190374	0.082125
2	PCA	2	12.311839	0.876426	0.162581	0.167150
3	SOM	8	18.128609	0.887715	0.171909	0.522324
4	SOM	4	25.755002	0.886623	0.150032	0.491865
5	SOM	2	13.279101	0.881889	0.149861	0.446407

نتایج مقایسه نشان می‌دهد که هر دو روش PCA و SOM عملکرد نسبتاً مشابهی در حفظ دقت طبقه‌بندی دارند، با این تفاوت که SOM در ابعاد بالاتر (8 بعدی) کمی دقت بهتری (88.77%) نسبت به PCA با (87.93%) ارائه می‌دهد. از نظر زمان آموزش، PCA در ابعاد پایین‌تر سریع‌تر عمل کرده، در حالی که SOM در ابعاد بالاتر زمان بیشتری نیاز دارد. نکته جالب توجه تفاوت معنادار در معیار Silhouette Score است که

نشان می‌دهد SOM توانسته ساختار خوش‌های بهتری ایجاد کند و این نشان می‌دهد SOM در حفظ ساختار محلی داده‌ها برتری دارد. از طرفی، ARI در PCA کمی بالاتر است که نشانگر تطابق بهتر با برجسب‌های واقعی است. به طور کلی هر دو روش عملکرد قابل قبولی دارند و اگر کیفیت خوش‌بندی مهم باشد، SOM گزینه بهتری محسوب می‌شود. تحلیل‌های بالا را در قالب یک نمودار بر اساس دقت برای درک بهتر در زیر نمایش دادیم و می‌توانیم در سه بعد 8، 4 و 2 در این دو مدل دقت کسب شده را ببینیم:



۶.

این پارت از ما می‌خواهد یک مدل چندلایه از شبکه‌های SOM طراحی کنیم که لایه‌های بالاتر آن بتوانند مناطق پرترکم داده را با دقت بیشتری تحلیل کنند و ساختار داده‌ها را بهتر نمایش دهند. در این کد ابتدا یک SOM اولیه با شبکه 5×5 آموزش دادیم تا ساختار کلی داده‌ها را یاد بگیرد. سپس داده‌های آموزشی را بر اساس نورون‌های فعال در این شبکه دسته‌بندی کرده و برای هر ناحیه پرترکم (با حداقل 5% داده)، یک SOM ثانویه 3×3 آموزش دادیم. در نهایت با تابع `hierarchical_embedding`، هر نمونه داده را به یک بردار چهار بعدی تبدیل کردیم که شامل مختصات نورون فعال در SOM اولیه و در صورت وجود، مختصات مربوطه در SOM ثانویه است. این رویکرد سلسله‌مراتبی امکان تحلیل دقیق تر نواعی پرترکم داده را فراهم می‌کند. در ادامه یک مدل Random Forest روی داده‌های تبدیل شده به فضای سلسله‌مراتبی آموزش دادیم و معیارهای دقت (Accuracy)، تطابق خوش‌های (ARI) و کیفیت خوش‌بندی (Silhouette) و همچنین زمان آموزش مدل را محاسبه کردیم تا عملکرد این روش را ارزیابی کنیم.

خروجی این بخش به صورت زیر در آمد و نتایج نشان می‌دهد مدل سلسله‌مراتبی با وجود مزایای نظری، در عمل عملکرد ضعیفتری نسبت به SOM ساده داشته است. دقت پایین‌تر احتمالاً به دلیل پیچیدگی بیش از حد مدل برای این مجموعه داده خاص است که منجر به کاهش توان تعمیم‌پذیری شده است. مقدار ARI نسبتاً پایین نیز نشان می‌دهد ارتباط ضعیفی بین خوش‌های شناسایی شده Silhouette Score بسیار پایین نیز تأیید می‌کند که

خوشه‌ها به خوبی از هم تفکیک نشده‌اند. همچنین زمان آموزش کوتاه‌تر ممکن است به دلیل کاهش ابعاد موثر داده در روش سلسله‌مراتبی باشد. به نظر می‌رسد این معماری برای این مجموعه داده نیاز به تنظیم دقیق‌تر پارامترها دارد اما به دلیل به پایان رسیدن دلالین این تمرین و نبودن فرصت کافی، فرصتی برای بهبود و افزایش این معیارهای ارزیابی در پارت ششم مهیا نشد و خروجی این بخش نیز به شرح زیر می‌باشد:

```
Hierarchical SOM Embedding:  
Accuracy: 0.7645  
ARI: 0.1592  
Silhouette: 0.11374255096235171  
Training Time: 2.9253 seconds
```

«... اردیبهشت‌ماه ۱۴۰۴»