

«*In The Name Of GOD*»



دانشگاه صنعتی امیرکبیر  
(پلی تکنیک تهران)

## [HW-06-Report]

[NEURAL COMPUTING AND DEEP LEARNING]

Hasan Masroor | [403131030] | June 10, 2025

## "فهرست مطالب تمرین 06"

Question 1 .....	2
1) .....	2
2) .....	2
3) .....	4
4) .....	17
5) .....	19
6) .....	21
7) .....	25
Question 2 .....	29
1) .....	29
2) .....	29
3) .....	29
4) .....	31

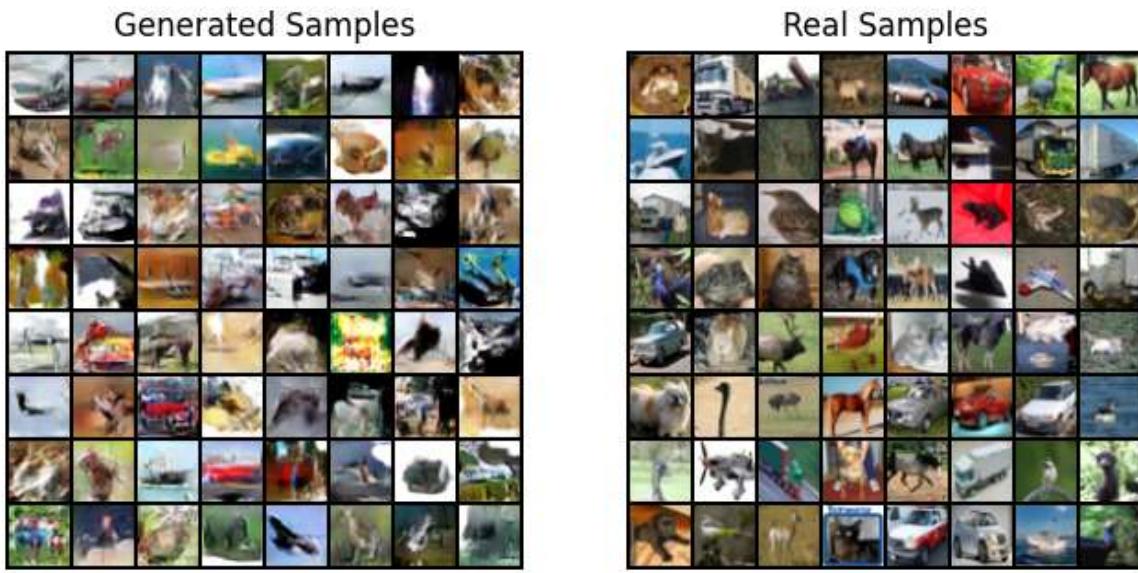
## Problem 6: Generative Adversarial Networks (GAN)

:Question 1 

.1&2

در این تمرین، هدف ما بررسی و ارزیابی مدل‌های مختلف شبکه‌های مولد تصاویر واقعی است. ابتدا ما مدل پایه DCGAN را پیاده‌سازی کرده و سپس با اعمال تغییرات مختلف در ساختار و تکنیک‌ها، سعی کردیم عملکرد آن را بهبود دهیم. در طول تمرین، آزمایش‌های مختلفی انجام دادیم که شامل تحلیل تأثیر پارامترهایی مانند اندازه بردار نویز ورودی، استفاده از Batch Normalization و انتخاب توابع فعال‌سازی متفاوت بود. بعد از پیاده‌سازی مدل‌های پایه، به سراغ مدل‌های Wasserstein GAN و Conditional GAN رفتیم تا قابلیت‌های هر یک را در تولید تصاویر با کیفیت و پایدار بررسی کنیم. سپس برای مقایسه کیفیت تصاویر تولیدی با تصاویر واقعی، از معیارهای مختلفی مانند Inception Score و FID استفاده کردیم. در نهایت، توزیع تصاویر واقعی و تولیدی را در فضای ویژگی با استفاده از تکنیک‌هایی مثل t-SNE یا UMAP مورد بررسی قرار دادیم تا میزان شباهت و کیفیت تصاویر تولیدی را ارزیابی کنیم.

در این قسمت، ما ابتدا مدل پایه DCGAN را برای تولید تصاویر از مجموعه داده CIFAR-10 پیاده‌سازی کردیم. ابتدا با استفاده از شبکه‌های کانولوشن ترانسپوز (ConvTranspose2d)، مولد (Generator) و متمایزکننده (Discriminator) را ساختیم. مولد تصاویر تصادف را از بردار نویز به تصاویر  $32 \times 32$  تبدیل می‌کند، در حالی که متمایزکننده تلاش می‌کند تا تصاویر واقعی و تولیدی را از هم تشخیص دهد، سپس با استفاده از تابع ضرر BCELoss، مدل آموزش دید و بهینه‌سازی با الگوریتم Adam انجام شد. در طول آموزش، به صورت دوره‌ای تصاویر تولیدشده ذخیره و مقایسه شدند و با استفاده از معیارهای (IS) Inception Score و (FID) Inception Distance کیفیت تصاویر تولیدی را ارزیابی کردیم و در نهایت برای تجزیه و تحلیل بهتر تصاویر واقعی و تولیدشده را در خروجی زیر نمایش دادیم:



همانطور که در تصاویر بالا می بینیم نمونه های تولید شده هرچند ساختارهای کلی را باز تولید می کنند، اما به دلیل Mode Averaging، با محشودگی لبه ها و فقدان جزئیات موواجه می شوند که در مقایسه با تصاویر واضح و متنوع مجموعه داده CIFAR-10 قابل توجه است. این امر نشان دهنده چالش مدل در یادگیری کامل توزیع داده ها و دستیابی به همگرایی مطلوب است و می تواند به دلیل تعداد اپک ها هم باشند و با افزایش آنها بهبود بهتری حاصل شود.

FID 54.68      IS  $3.65 \pm 0.04$

با توجه به نتایج به دست آمده از معیارهای ارزیابی، Inception Score برابر با 3.65 نشان دهنده کیفیت نسبی خوب تصاویر تولیدی است اما هنوز فاصله قابل توجهی با مقادیر ایده آل دارد. همچنین، مقدار Frechet Inception Distance (FID) برابر با 54.68 نشان دهنده تفاوت قابل توجه میان توزیع ویژگی های تصاویر واقعی و تولیدی است و نیاز به بهبود بیشتر در کیفیت تصاویر تولیدی و هم راستایی بهتر با تصاویر واقعی است.

در ادامه نیز نمودارهای Loss مربوط به مولد و متمازکننده را برای تحلیل بهتر نشان دادیم و نمودار Loss نشان دهنده کاهش اولیه قابل توجه Loss مولد (Generator) تا حدود اپک 5 است که با ثبت در سطح 1.5 تا 2.0 همراه می شود، در حالی که Loss متمازکننده (Discriminator) به تدریج افزایش یافته و در محدوده 0.5 تا 1.0 پایدار می ماند. نمودار Loss را در پایین نمایش دادیم:



### 3

برای بررسی تأثیر اندازه بردار نویز ورودی بر عملکرد مدل DCGAN، آزمایش‌هایی با دو مقدار متفاوت برای ابعاد بردار نویز، یعنی 50 و 200 انجام دادیم. هدف از این آزمایش‌ها، ارزیابی تأثیر اندازه فضای نهان بر کیفیت و تنوع تصاویر تولید شده بود. در این مرحله تمامی تنظیمات دیگر ثابت نگه داشته شدند تا بتوانیم به صورت کنترل شده فقط نقش بردار نویز ورودی را تحلیل کنیم.

ساختار مدل در هر دو حالت ثابت بود و شامل یک Generator با معماری کلاسیک DCGAN می‌شد. در Generator بردار نویز از اندازه مشخص شده به صورت تصادفی تولید و پس از عبور از چند لایه ConvTranspose2d و ReLU و BatchNorm تصویر با ابعاد 32x32 ساخته می‌شد. Discriminator نیز وظیفه تفکیک تصاویر واقعی از جعلی را بر عهده داشت و شامل چند لایه Conv2d همراه باReLU و در نهایت تابع خروجی Sigmoid بود.

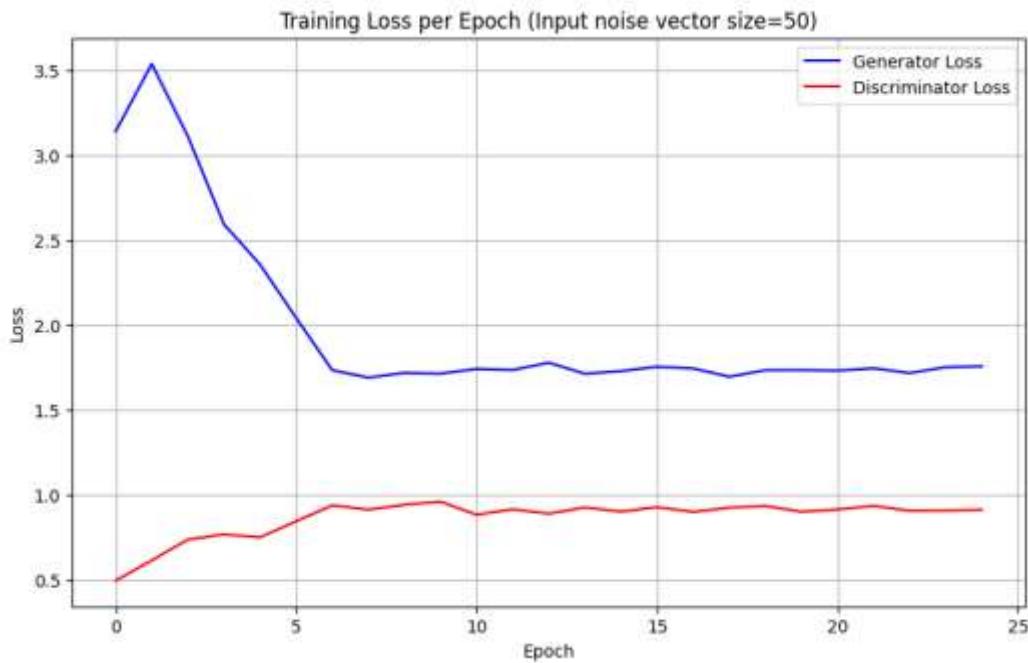
در هر دو آزمایش، از تابع زیان Binary Cross-Entropy و بهینه‌ساز Adam برای بهروزرسانی شبکه‌ها استفاده کردیم. برای ارزیابی کیفی خروجی‌ها، پس از پایان آموزش در هر حالت، ده هزار تصویر تولید و با استفاده از معیارهای IS و FID تحلیل شدند. علاوه بر آن، نمودار تغییرات لاس Generator و Discriminator در طول دوره آموزش نیز مثل بخش قبل رسم شد تا روند یادگیری مدل در مواجهه با بردارهای نویز متفاوت مورد بررسی قرار گیرد. این مقایسه به ما کمک می‌کند تا درک بهتری از نقش اندازه فضای نهان در کیفیت و تنوع تصاویر تولیدی داشته باشیم.

### -Input noise vector size:

- Size=50

نمودار Loss برای مدل با اندازه بردar نویز 50 نشان دهنده کاهش قابل توجه اولیه Loss Generator از 3.5 به حدود 1.8 در طی 5 اپک اول است که با ثبیت نسبی در محدوده 1.5 تا 2.0 تا پایان 25 اپک همراه می شود، در حالی که Loss Discriminator پس از افزایش اولیه، به تدریج در محدوده 0.5 تا 1.0 پایدار می ماند. این الگو حاکی از تطابق مناسب Generator با بازخورد Discriminator و تلاش برای یادگیری توزیع داده ها است که با مقادیر ارزیابی IS 3.77 و FID 57.65 تأیید می شود. این مقادیر نشان دهنده کیفیت قابل قبول تصاویر تولید شده است، هرچند هنوز با تصاویر واقعی فاصله دارد. ثبات نسبی Loss ها در فازهای پایانی بیانگر دستیابی به یک تعادل نسبی در آموزش است.

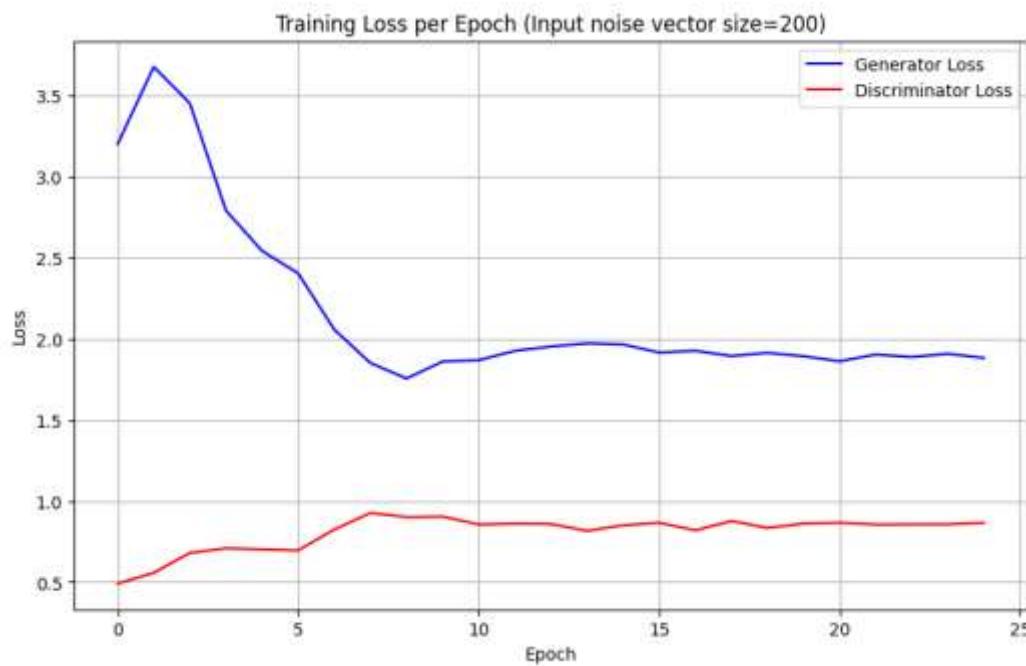
nz50 IS 3.77 ± 0.10 | FID 57.65



- Size=200

نمودار Loss برای مدل با اندازه بردar نویزرا 200 مثل بخش قبل می توانیم تحلیل کنیم و این نمودار نشان دهنده کاهش قابل توجه اولیه Loss Generator از 3.5 به حدود 1.8 در طی 5 اپک اول است که با ثبیت نسبی در این محدوده تا پایان 25 اپک همراه می شود، در حالی که Loss Discriminator پس از افزایش اولیه در محدوده

0.5 تا 1.0 به صورت پایدار باقی می‌ماند. این رفتار منعکس کننده توانایی Generator در تطبیق با فضای Latent بزرگ‌تر و تولید تنوع بیشتر است، که با مقادیر ارزیابی 3.60 IS و 59.14 FID پشتیبانی می‌شود. این مقادیر نشان‌دهنده کیفیت تصاویر تولید شده در سطحی مشابه با اندازه 50، اما با کمی کاهش IS و افزایش FID است. ثبات نسبی Loss‌ها در فازهای پایانی حاکی از تعادل مناسب بین Generator و Discriminator است و با این حال افزایش اندازه بردار نویز ممکن است پیچیدگی یادگیری را بالا برد.  
nz200 IS 3.60 ± 0.10 | FID 59.14



### -Batch Normalization:

- Only Generator

در این بخش، به منظور بررسی تأثیر Batch Normalization بر کیفیت و پایداری آموزش مدل DCGAN، سه سناریوی مختلف طراحی و اجرا شده‌اند. در این آزمایش‌ها، لایه‌های Batch Normalization به صورت جداگانه و ترکیبی روی دو بخش اصلی مدل، یعنی Generator و Discriminator اعمال شدند. حالت اول شامل استفاده از Generator Batch Normalization فقط در Generator، حالت دوم تنها در Discriminator و حالت سوم در هر دو شبکه بود. هدف اصلی این بررسی، ارزیابی تأثیر نرمال‌سازی داخلی لایه‌ها بر روند همگرایی مدل،

پایداری loss‌ها و کیفیت نهایی تصاویر تولیدی است. در تمامی آزمایش‌ها، معماری کلی هر دو شبکه ثابت باقی ماند و تنها تفاوت در فعال یا غیرفعال بودن لایه‌های BatchNorm2d بود. پیاده‌سازی این کنترل از طریق پارامترهای Generator و bn\_D و bn\_G و bn انجام شد. در سه لایه BatchNorm2d پس از لایه‌های ConvTranspose2d و پیش از ReLU قرار دارند. در نیز دو لایه BatchNorm2d در مسیر ۲۵ پردازش تصاویر پس از لایه‌های Convolution درج می‌شوند. طبق روال فرآیند آموزش در هر سناریو به مدت اپک انجام شده است. در هر دوره، ابتدا Discriminator با تصاویر واقعی و تولیدی آموزش می‌بیند، سپس Generator به گونه‌ای به روزرسانی می‌شود که بتواند Discriminator را فریب دهد. همچنین ازتابع BCELoss به عنوان تابع هزینه و بهینه‌ساز Adam استفاده شد

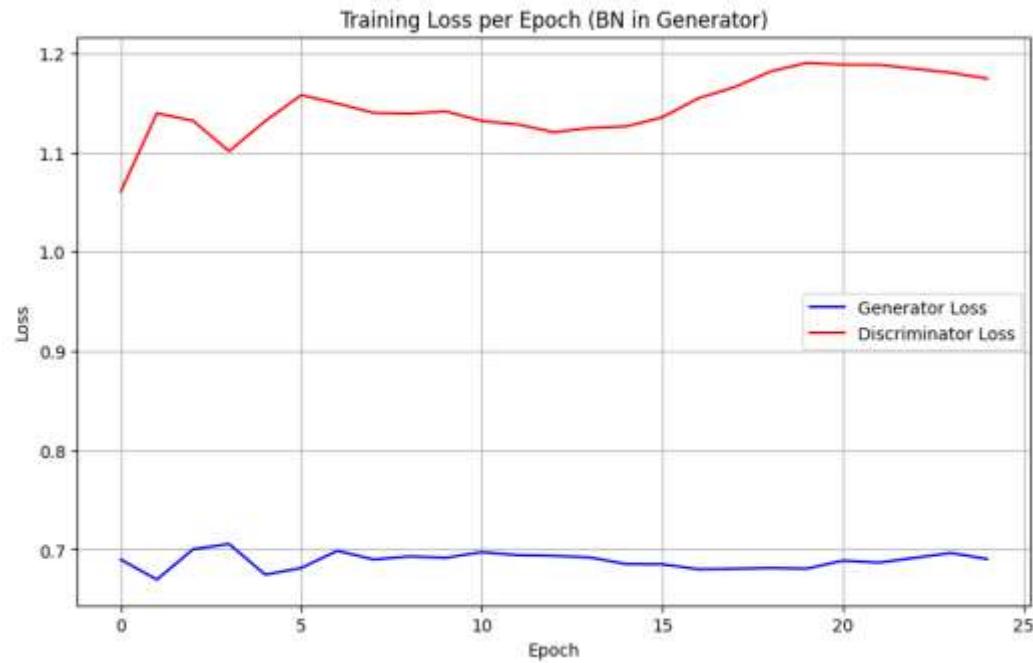
در ادامه خروجی‌های حالت اول یعنی فقط روی مولد را اعمال و نمایش دادیم:

IS 2.42 ± 0.03 FID 135.17

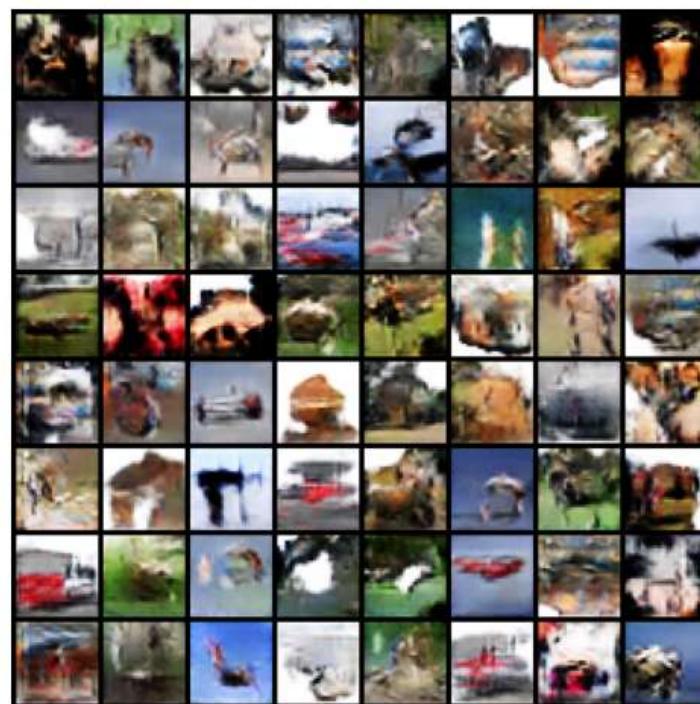


نمودار Loss برای مدل با اعمال (BN) Generator تنها در Batch Normalization نشان‌دهنده کاهش اولیه Loss Generator به حدود 0.7 و ثبیت آن در محدوده 0.7 تا 0.8 در طول 25 اپک است، در حالی که Loss Discriminator پس از افزایش اولیه به حدود 1.1، با نوسانات جزئی در محدوده 1.0 تا 1.2 باقی می‌ماند. این الگو بیانگر تلاش Generator برای تطبیق با داده‌ها با استفاده از BN است اما مقادیر ارزیابی IS 2.42 و FID 135.17 نشان‌دهنده کیفیت پایین تصاویر تولیدشده و فاصله قابل توجه از توزیع واقعی هستند که با مشاهده

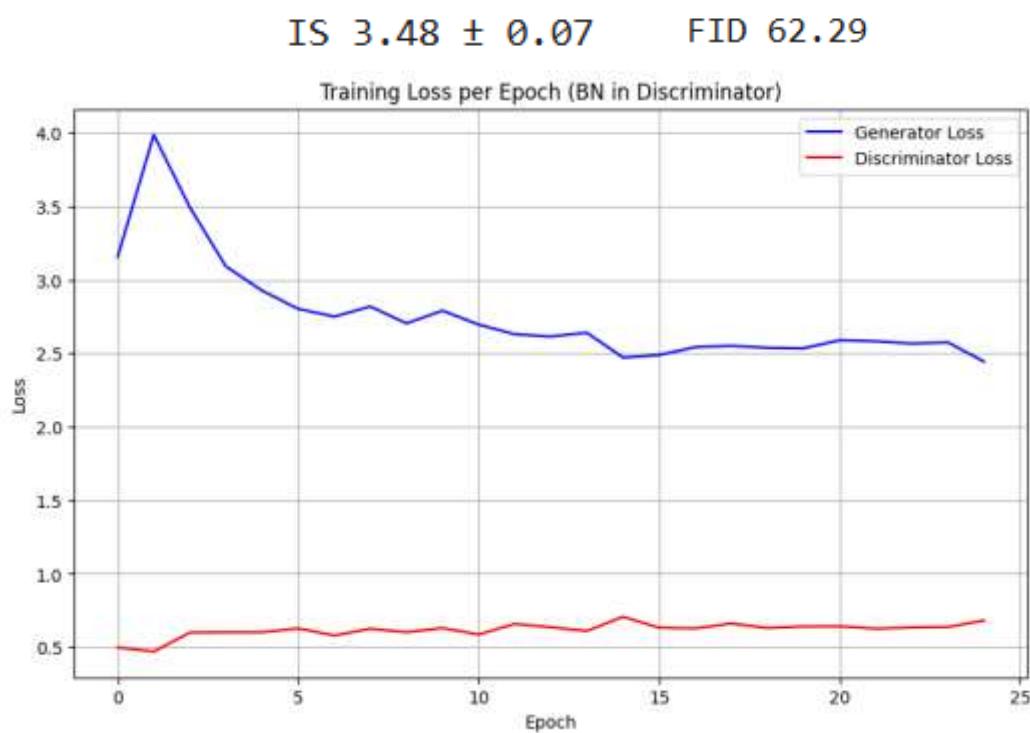
کم کیفیت و کم‌وضوح بودن تصاویر نمونه‌ها هم راستاست. ثبات نسبی Loss Generator ممکن است به دلیل تأثیر مثبت BN در کاهش نویز داخلی باشد.



- Only Discriminator



نمودار Loss برای مدل با اعمال (BN) نشان‌دهنده کاهش قابل توجه اولیه Loss Generator از 4.0 به حدود 2.5 در طی 5 اپک اول است که با ثبیت نسبی در این محدوده تا پایان 25 اپک همراه می‌شود، در حالی که Loss Discriminator پس از افزایش اولیه در محدوده 0.5 تا 1.0 به صورت پایدار باقی ماند. این الگو حاکی از تلاش Generator برای تطبیق با داده‌ها با وجود تأثیر BN در Discriminator است که با مقادیر ارزیابی IS 3.48 و FID 62.29 نیز حاکی از این ماجرا است. این مقادیر نشان‌دهنده تلاش مدل برای تولید تصاویر با کیفیت قابل قبول هستند، هرچند تصاویر خروجی دارای مقداری نویز و محوشی هستند که می‌تواند به دلیل کم بودن تعداد اپک‌ها و آموخته ناکاف مدل باشد.

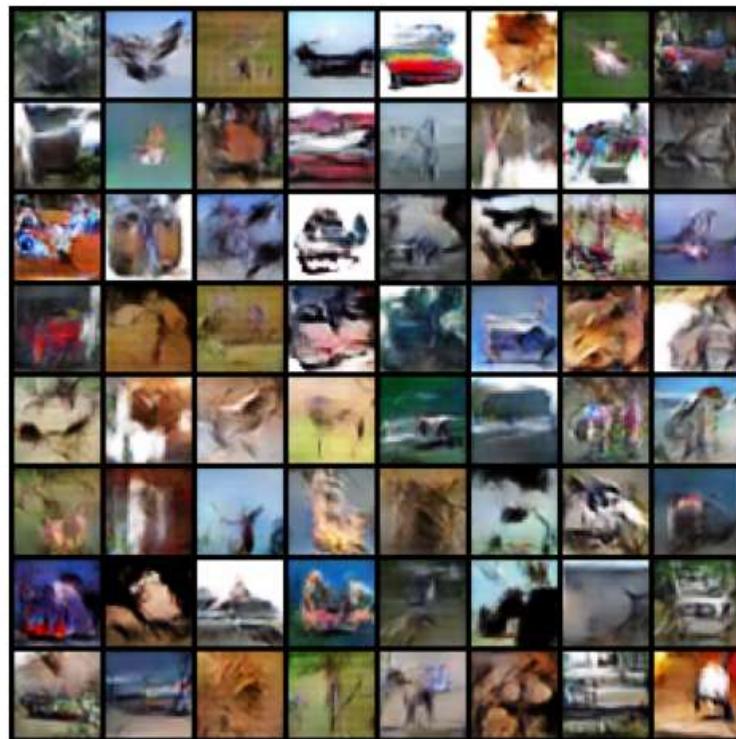


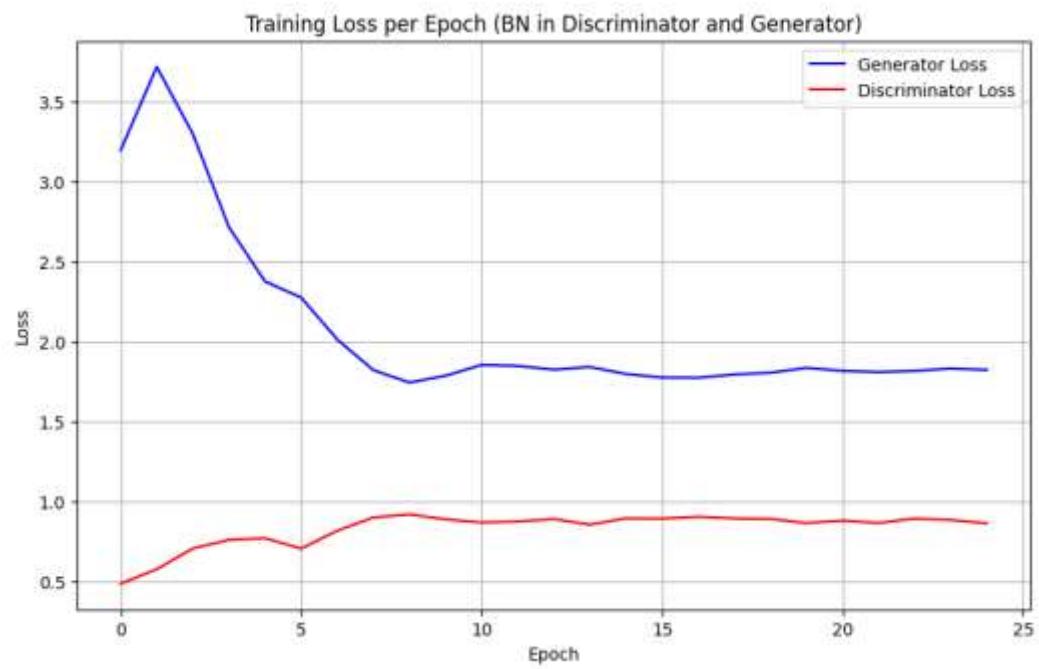
#### ■ Generator & Discriminator

نمودار Loss برای مدل با اعمال (BN) هم در Generator و هم در Discriminator نشان‌دهنده کاهش قابل توجه اولیه Loss Generator از 3.5 به حدود 2.0 تا 2.5 در طی 5 اپک اول است که با ثبیت نسبی در این محدوده تا پایان 25 اپک همراه می‌شود در حالی که Loss Discriminator پس از افزایش اولیه، در محدوده 0.5 تا 1.0 به صورت پایدار باقی ماند. این الگو حاکی از

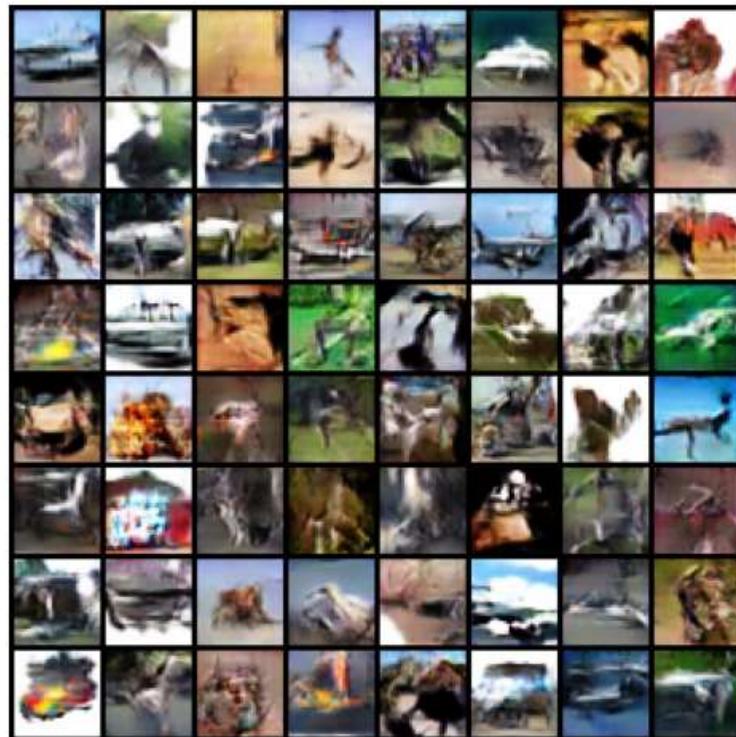
هماهنگی مناسب بین Generator و Discriminator در مقابل دو حالت قبلی یعنی فقط مولد یا فقط متمايزکننده است که مقادیر ارزیابی IS 3.54 و FID 57.07 نیز عملکرد بهتر این بخش نسبت دو حالت گذشته را نشان می دهد. این مقادیر نشان دهنده کیفیت قابل قبول تصاویر تولید شده هستند، هرچند تصاویر نمونه ها دارای مقداری نویز ووضوح محدود هستند. ثبات نسبی Loss ها در فازهای پایانی نیز بیانگر پیشرفت در فرآیند آموزش و تعادل مناسب بین اجزای مدل است.

IS  $3.54 \pm 0.09$       FID  $57.07$



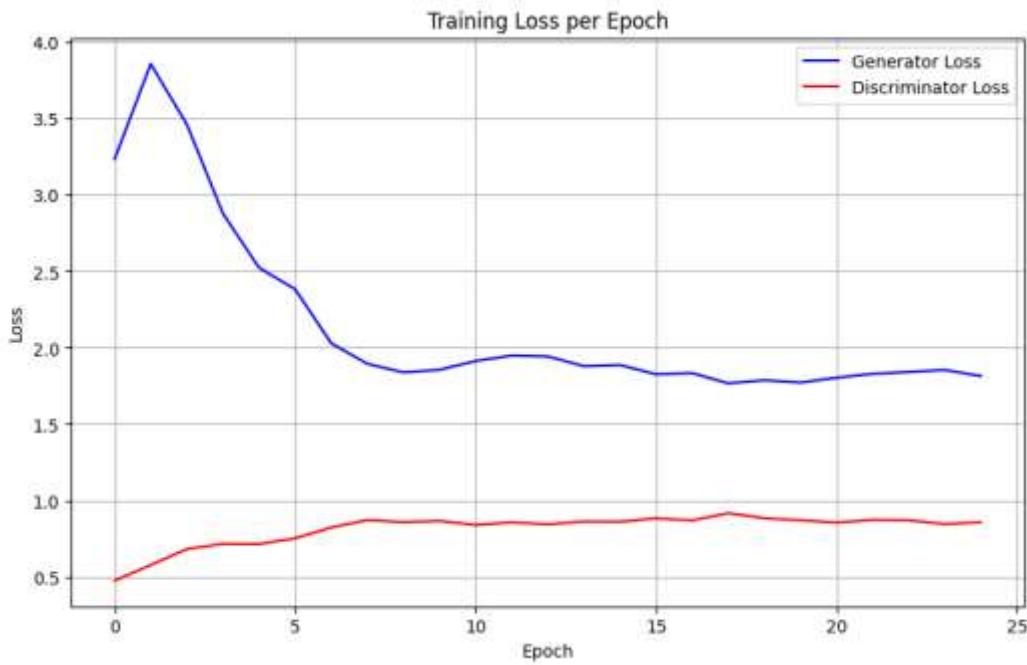


- **Label Smoothing:**



در این بخش به منظور بررسی تأثیر Label Smoothing بر پایداری فرآیند آموزش و کیفیت تصاویر تولید شده، تغییری در مقدار برچسب واقعی در تابع هزینه Discriminator اعمال شده است. به جای استفاده از مقدار 1 برای برچسب تصاویر واقعی، مقدار نرم شده‌ی 0.9 انتخاب شده است. این تکنیک که با نام label smoothing شناخته می‌شود و با هدف جلوگیری از بیش اعتماد شدن Discriminator طراحی شده و از غلبه‌ی بیش از حد آن Generator جلوگیری می‌کند. برای پیاده‌سازی این تکنیک، مقدار برچسب واقعی از طریق پارامتر `ls=True` در `real_label` در پیکربندی تنظیم شده و به صورت شرطی از طریق کلید `ls` کنترل می‌شود. در صورتی که `ls` باشد، برچسب‌های واقعی در طول آموزش مقدار 0.9 دریافت می‌کنند و در غیر این صورت برابر 1 باقی مانند. این برچسب‌ها در قالب تنسور `real_lbl` برای استفاده در BCELoss آماده می‌شوند و در محاسبه‌ی loss مربوط به Generator و Discriminator به کار می‌روند. در سایر بخش‌های مدل، ساختار شبکه‌های مشابه تنظیمات پایه DCGAN حفظ شده و تنها تغییر اعمال شده مربوط به Generator و Discriminator جایگزینی مقدار برچسب واقعی است. در ادامه خروجی‌های این بخش را مشاهده می‌کنیم:

$$\text{IS } 3.68 \pm 0.07 \quad \text{FID } 56.72$$



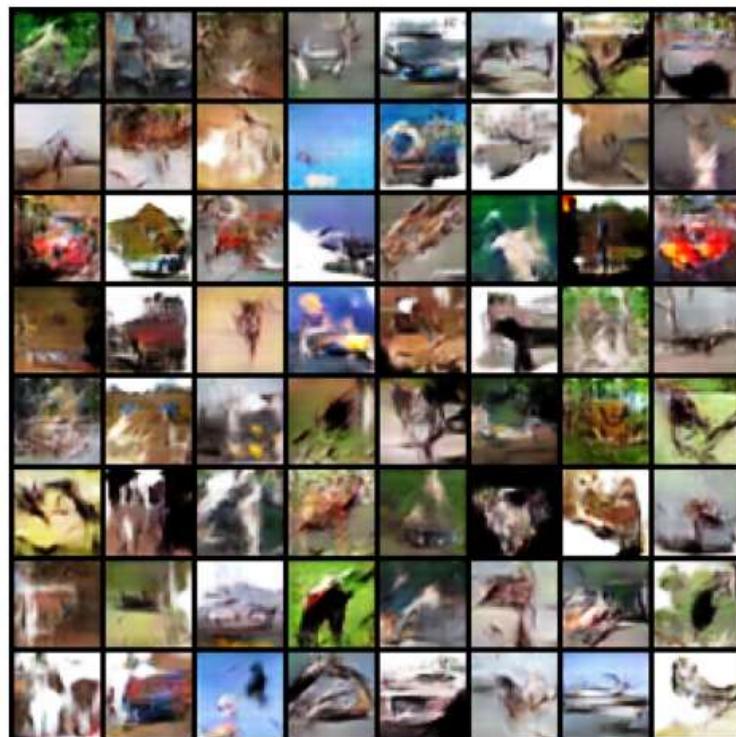
نمودار Loss برای مدل با اعمال Label Smoothing نشان‌دهنده کاهش قابل توجه اولیه Loss Generator از 4.0 به حدود 2.0 تا 2.5 در طی 5 epoch اول است، که با ثبت نسبی در این محدوده تا پایان 25 epoch همراه می‌شود، در حالی که Loss Discriminator پس از افزایش اولیه، در محدوده 0.5 تا 1.0 به صورت پایدار باقی ماند. این الگو حاکی از تأثیر مثبت Label Smoothing در بهبود تطابق Generator با داده‌ها و تعادل مناسب با Discriminator است، که با مقادیر ارزیابی IS  $3.68 \pm 0.07$  و FID 56.72 پشتیبانی می‌شود؛ این مقادیر نشان‌دهنده کیفیت بهتری در تصاویر تولید شده نسبت به تنظیمات قبلی هستند و بیانگر کاهش فاصله از توزیع واقعی است.

### -Activation Function:

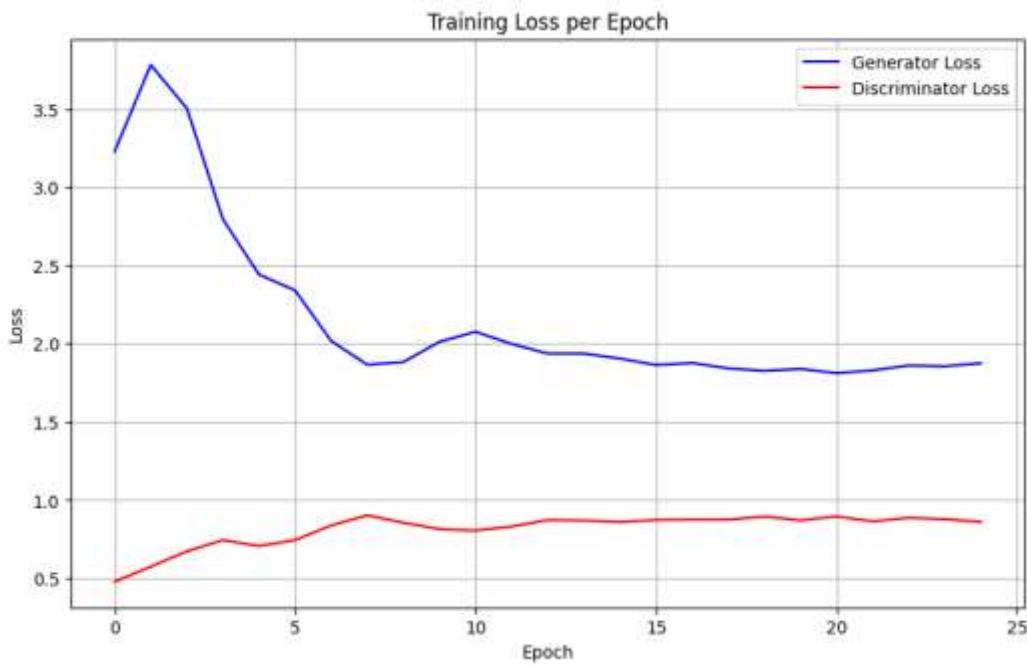
- Generator = ReLU, Discriminator = LeakyReLU

در این بخش، برای بررسی تأثیر تابع فعال سازی بر عملکرد DCGAN، سه ترکیب متفاوت از توابع فعال سازی در ساختار Generator و Discriminator مورد آزمایش قرار گرفت. در حالت اول، از ترکیب رایج ReLU در Generator و Discriminator استفاده کردیم. این ترکیب باعث می شود Generator و Discriminator با استفاده از بتواند گرادیان های واضح تری برای تولید تصاویر یاد بگیرد و در عین حال Discriminator vanishing gradient را در Generator دچار مشکل نشود. در حالت دوم ترکیب ReLU در Generator و LeakyReLU در Discriminator به کار گرفته شد. با اینکه Tanh در لایه خروجی Generator متداول است، استفاده از آن در Discriminator به دلیل اشباع گرادیان در بازه های بزرگ تر چندان توصیه نمی شود. نتایج این آزمایش نیز نشان داد که این ترکیب باعث ناپایداری در آموزش و کاهش کیفیت خروجی ها می شود. در حالت سوم، هر دو شبکه از LeakyReLU استفاده کردند. این انتخاب به Generator امکان عبور بهتر گرادیان را می دهد و از قفل شدن نورون ها جلوگیری می کند. در برخی نکارها، این ترکیب باعث همگرایی پایدار تر مدل و کاهش نوسانات Loss شد، گرچه گاهی کیفیت جزئیات تصویر کاهش یافت. خروجی های حالت اول به صورت زیر حاصل شده است:

FID 58.07      IS 3.48 ± 0.05



نمودار Loss برای مدل با استفاده از ReLU در LeakyReLU و Generator در Discriminator نشان دهنده کاهش قابل توجه اولیه Loss Generator از 3.5 به حدود 2.0 تا 2.5 در طی 5 اپک اول است در حالی که Loss Discriminator پس از افزایش اولیه، در محدوده 0.5 تا 1.0 به صورت پایدار باقی می ماند. مقادیر ارزیابی FID 58.07 و IS 3.48 نشان دهنده کیفیت متوسط تصاویر تولید شده با تنوع قابل قبول و فاصله نسبی از توزیع واقعی هستند. همچنین این مقادیر نشان دهنده کیفیت قابل قبول تصاویر تولید شده هستند و بیانگر تلاش مدل برای تطابق با توزیع داده هاست. ثبات Loss ها در فازهای پایانی، منعکس کننده تعادل خوب بین Generator و Discriminator است. نمودار لاس این بخش را در ادامه نمایش دادیم:

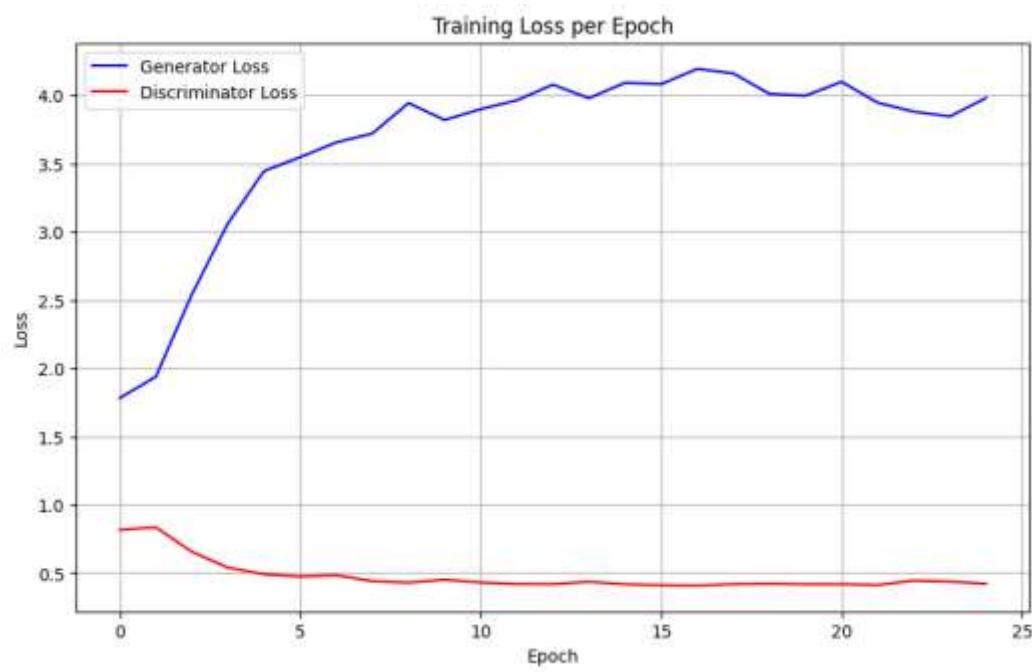


#### ▪ Generator = ReLU, Discriminator = Tanh

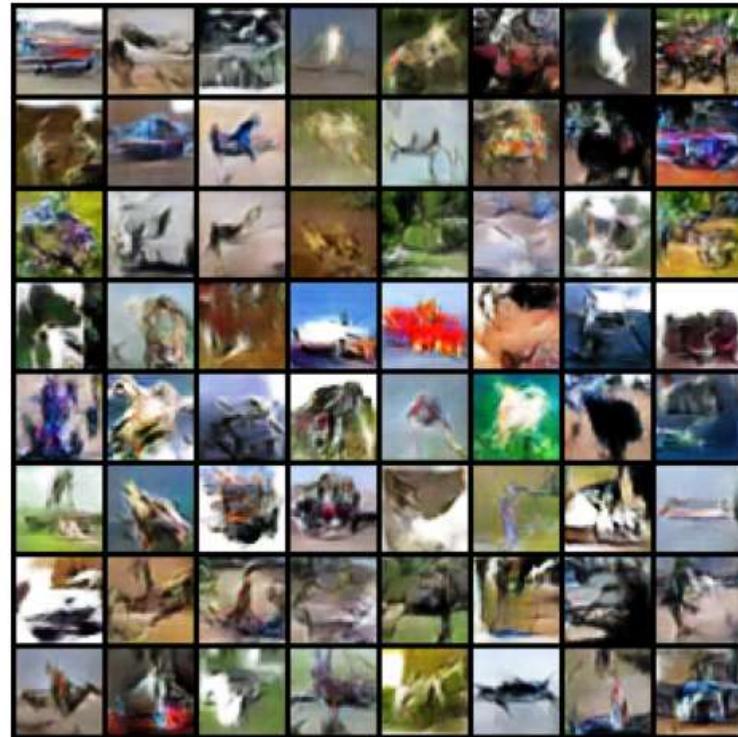
نمودار Loss برای مدل با استفاده از ReLU در Generator و Tanh در Discriminator نشان دهنده افزایش قابل توجه اولیه Loss Generator از 2.0 به حدود 4.0 در طی 5 اپک اول است، در حالی که Loss Discriminator پس از کاهش اولیه، در محدوده 0.5 تا 1.0 به صورت پایدار باقی می ماند. مقادیر ارزیابی IS 2.38 و FID 150.21 نشان دهنده چالش هایی در کیفیت تصاویر تولید شده با تنوع محدود و فاصله قابل توجه از توزیع واقعی هستند و بدترین حالت بین تمامی بخش های این تمرین می باشد و به دلیل اشباع گرادیان در بازه های بزرگ تر چندان توصیه نمی شود. نتایج این آزمایش نیز نشان داد که این ترکیب باعث ناپایداری در آموزش و کاهش چشمگیر کیفیت خروجی ها می شود.

در ادامه نیز خروجی های این قسمت را برای درک بصری آوردیم:

FID 150.21 IS  $2.38 \pm 0.02$

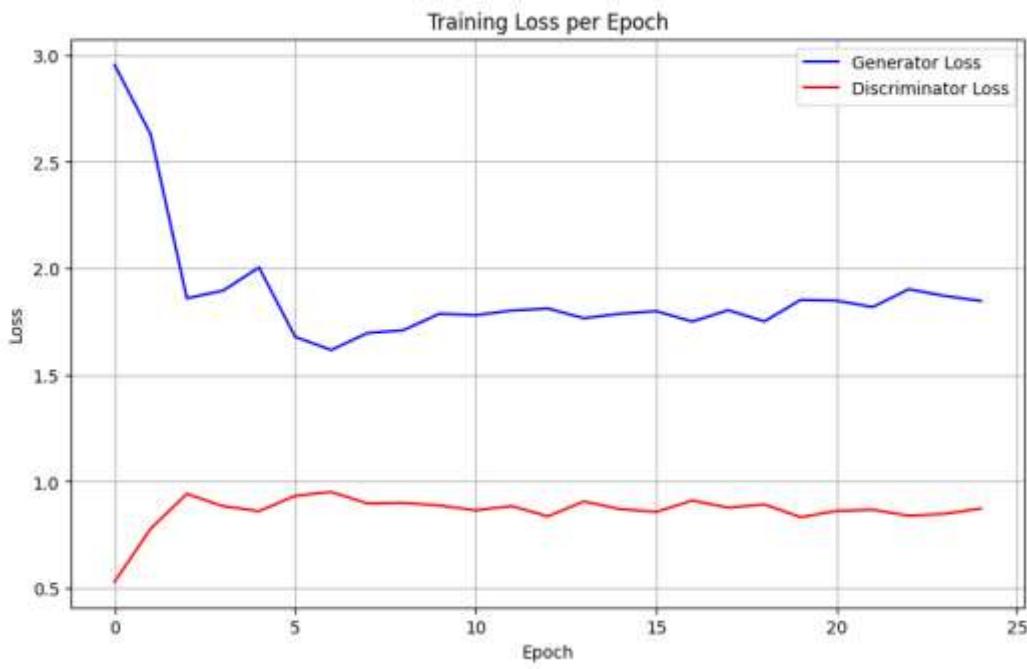


- Generator = LeakyReLU, Discriminator = LeakyReLU



نمودار Loss برای مدل با استفاده از Generator هم در Discriminator و هم در Generator نشان دهنده کاهش قابل توجه اولیه Loss Generator از 3.0 به حدود 2.0 در طی 5 اپک اول است، در حالی که Loss Discriminator پس از افزایش اولیه، در محدوده 0.5 تا 1 به صورت پایدار باقی می‌ماند. مقادیر ارزیابی IS 3.65 و FID 58.77 نشان دهنده کیفیت متوسط تصاویر تولید شده با تنوع قابل قبول و فاصله نسبی از توزیع واقعی هستند. همچنین این مقادیر نشان دهنده کیفیت قابل قبول تصاویر تولید شده هستند و بیانگر تلاش مدل برای تطابق با توزیع داده هاست. ثبات Loss ها در فازهای پایانی، منعکس کننده تعادل خوب بین Generator و Discriminator است.

FID 58.77      IS 3.65 ± 0.06



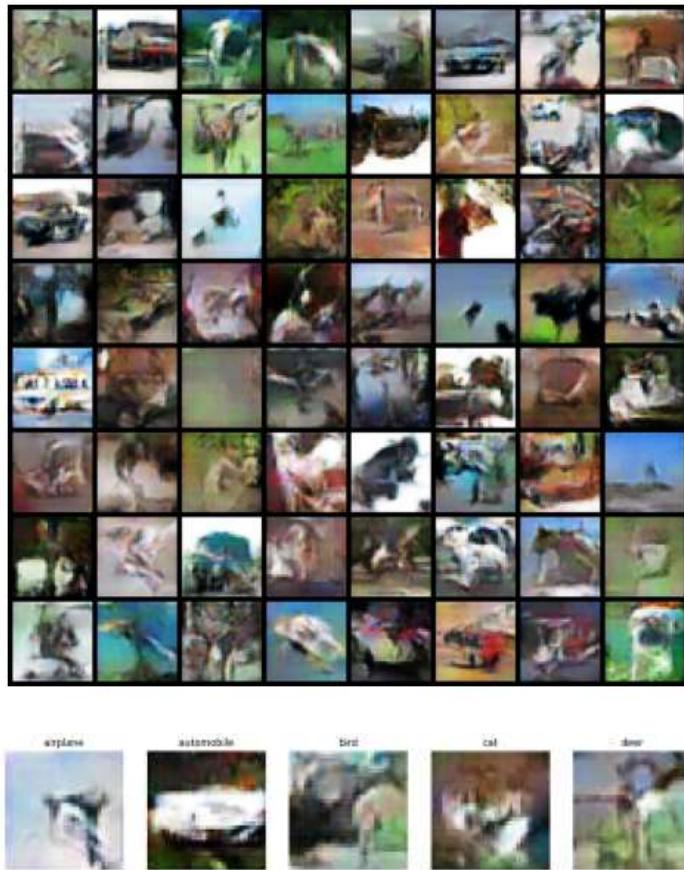
## 4

برای پیاده‌سازی مدل Conditional GAN (cGAN) که توانایی کنترل کلاس تصویر خروجی با استفاده از برجسب‌ها را داشته باشد، ابتدا یک معماری کلاسیک cGAN طراحی کردیم. در این مدل Generator با استفاده از ورودی تصادفی و برجسب کلاس، تصویر تولید می‌کند. این برجسب‌ها به وسیله یک لایه Embedding به Generator اضافه می‌شوند تا مدل قادر به تولید تصاویر متنوع از کلاس‌های مختلف باشد. از طرف دیگر، Discriminator به عنوان یک شبکه تفکیک کننده، وظیفه تشخیص تصاویر واقعی و مصنوعی را دارد اما این‌بار علاوه بر تصویر، برجسب کلاس نیز به ورودی‌های آن افزوده می‌شود تا مدل بتواند بر اساس کلاس‌های مختلف، واقعی بودن یا نبودن تصویر را شبیه‌سازی کند.

در بخش آموزش، شبکه‌های Generator و Discriminator به‌طور متناوب با استفاده از تابع زیان Binary Cross-Entropy به‌روز می‌شوند. این به‌روزرسانی‌ها باعث می‌شود که Generator بتواند تصاویر با کیفیت و واقع‌گرایانه‌تری تولید کند و Discriminator نیز به‌طور مؤثرتری تصاویر واقعی و مصنوعی را از هم تشخیص دهد.

در نهایت نیز نمونه‌ای از تصاویر تولید شده به همراه نمونه‌های 5 کلاس اول را در خروجی نمایش دادیم:

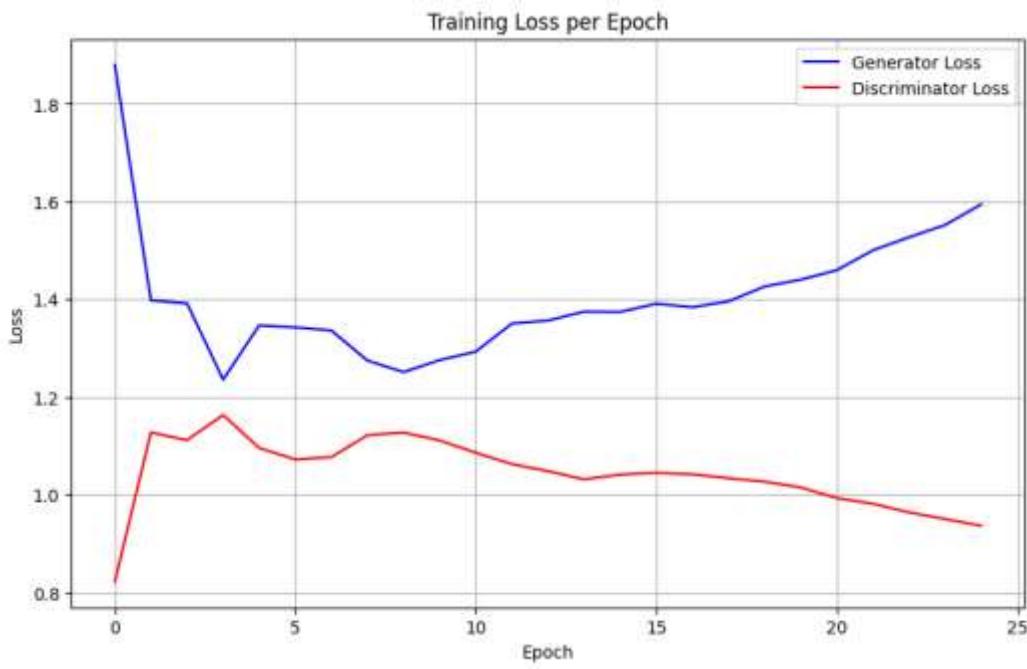
تصاویر تولید شده توسط مدل cGAN، با وجود تلاش برای بازتولید کلاس‌های مشخص (مانند airplane، automobile، deer، cat، bird)، از نظر وضوح و جزئیات کمی ضعیف بوده و تحت تأثیر نیز و محوش‌گی قرار دارند حاکی از آن است که مدل هنوز به همگرایی مطلوب نرسیده و ممکن است با افزایش تعداد اپک بهینه تر و ده و عملکرد بهتری از خود نشان دهد.



با توجه به مقادیر بدست آمده از ارزیابی مدل، می‌توان گفت که کیفیت تصاویر تولیدی به‌طور کلی قابل قبول است، اما هنوز جای پیشرفت وجود دارد. با توجه به مقدار IS که برابر 3.23 است، مدل توانسته است تصاویر نسبتاً متنوع و با کیفیتی تولید کند، هرچند که این مقدار به اندازه‌ای بالا نیست که نشان‌دهنده تولید تصاویر کاملاً طبیعی باشد. همچنین، مقدار FID برابر با 72.94 است که نشان‌دهنده فاصله بین توزیع ویژگی‌های تصاویر واقعی و تولید شده دارد. این مقادیر به ما می‌گویند که مدل هنوز به صورت کامل قادر به تولید تصاویری با کیفیت مشابه تصاویر واقعی نیست و نیاز به بهبود دارد.

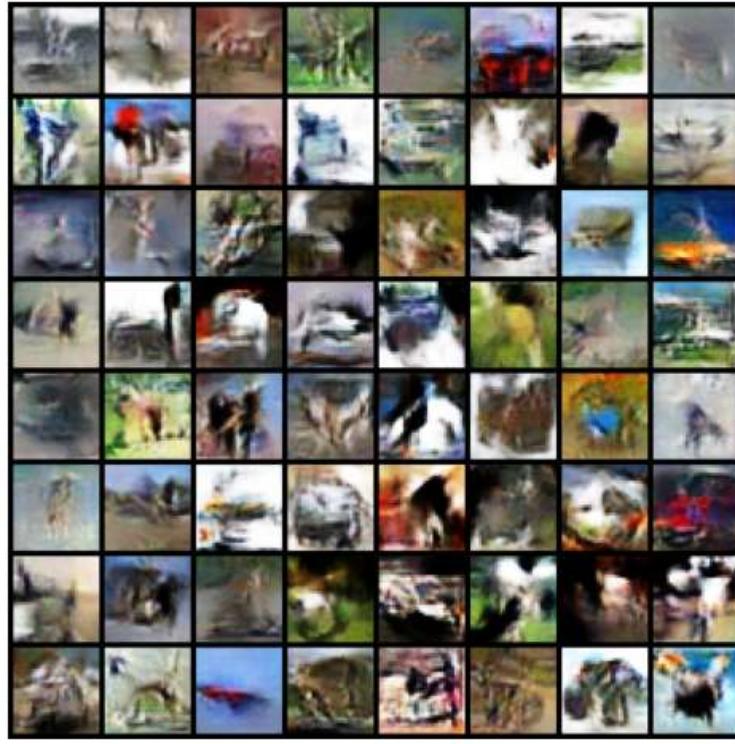
$$\text{FID } 72.94 \quad \text{IS } 3.23 \pm 0.08$$

نمودار Loss نشان‌دهنده کاهش اولیه Generator مربوط به Loss تا حدود 5 اپک و سپس افزایش تدریجی آن تا سطح 1.6 در پایان دوره‌های آموزشی است، در حالی که Loss مربوط به Discriminator پس از افزایش اولیه، به تدریج کاهش یافته و در محدوده 0.8 تا 1.0 به ثابت نسبی نزدیک می‌شود؛ این روند بیانگر کاهش پایداری این مدل و احتمال ضعف مولد در فریب متمازنده است که می‌تواند ناشی از تعداد اپک کمتر باشد.



## ۵

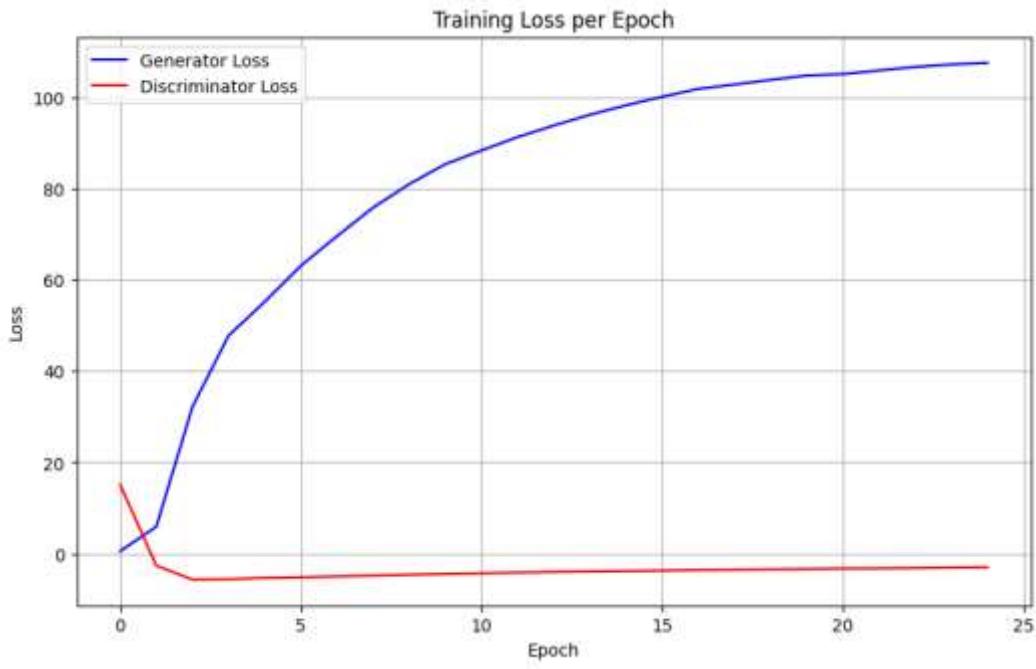
برای پیاده‌سازی مدل (WGAN-GP) (Wasserstein GAN with Gradient Penalty)، ابتدا معماری اصلی این مدل را طراحی کردیم که از یک Generator و Discriminator استاندارد تشکیل شده است. در این مدل، Generator با ورودی تصادفی، تصاویری تولید می‌کند که باید از لحاظ توزیع مشابه با داده‌های واقعی باشند. Discriminator یا همان Critic، این بار نه به صورت کلاسیک، بلکه به عنوان یک تابع فاصله Wasserstein عمل می‌کند و مقادیر امتیازی برای هر تصویر تولید شده ارائه می‌دهد. برای بهبود عملکرد Model و جلوگیری از ناپایداری‌های معمول در آموزش GAN‌ها، از تکنیک Gradient Penalty استفاده می‌کنیم که با اعمال یک جریمه به گرادیان‌ها موجب بهبود همگرایی مدل می‌شود. در بخش آموزش، Generator و Discriminator به طور متناوب با استفاده از تابع زیان Wasserstein و جریمه گرادیان به روز می‌شوند. به طور خاص، Discriminator باید مقادیر مشابه‌تری برای تصاویر واقعی و مصنوعی ایجاد کند و Generator باید تصاویری تولید کند که Discriminator قادر به تمایز آن‌ها از تصاویر واقعی نباشد. این به روزرسانی‌ها باعث می‌شود که Generator بتواند تصاویر واقع گرایانه‌تری تولید کند و Discriminator به طور مؤثرتری این تصاویر را ارزیابی کند. در ادامه خروجی تصاویر این بخش را نیز نمایش می‌دهیم:



برای ارزیابی مدل WGAN-GP نیز از دو معیار IS و FID استفاده کردیم. مقدار IS برابر با 3.29 به دست آمد که نشان‌دهنده توانایی مدل در تولید تصاویر متنوع و با ویژگی‌های پیچیده است؛ همچنین، مقدار FID برابر با 72.94 به دست آمد که از فاصله قابل توجهی میان توزیع تصاویر واقعی و تولید شده حکایت دارد. با این حال، این مقدار هنوز در محدوده متوسط قرار دارد و بهبودهایی در تولید تصاویر واقعی‌تر می‌تواند نتایج بهتری ارائه دهد.

$$\text{IS } 3.29 \pm 0.07 \quad \text{FID } 72.94$$

نمودار Loss برای مدل WGAN-GP نشان‌دهنده رفتار متمایز در فرآیند آموزشی است، با افزایش تدریجی Loss Generator از مقادیر اولیه به بیش از 100 در طول 25 اپک، در حالی که Loss Discriminator پس از کاهش اولیه به سطح نزدیک به صفر در یک دامنه پایین و پایدار باقی می‌ماند. این الگو حاکی از تلاش Generator برای اکتشاف گستره‌تر فضای Latent و تولید تنوع بیشتر در تصاویر است، در حالی که Discriminator با ثبات در عملکرد خود بازخورد مؤثری برای بهبود کیفیت ارائه می‌دهد. برای بهینه‌سازی بیشتر، افزایش تعداد اپک‌ها می‌تواند به دستیابی به همگرایی بهینه و کیفیت بالاتر تصاویر منجر شود.



## 6.

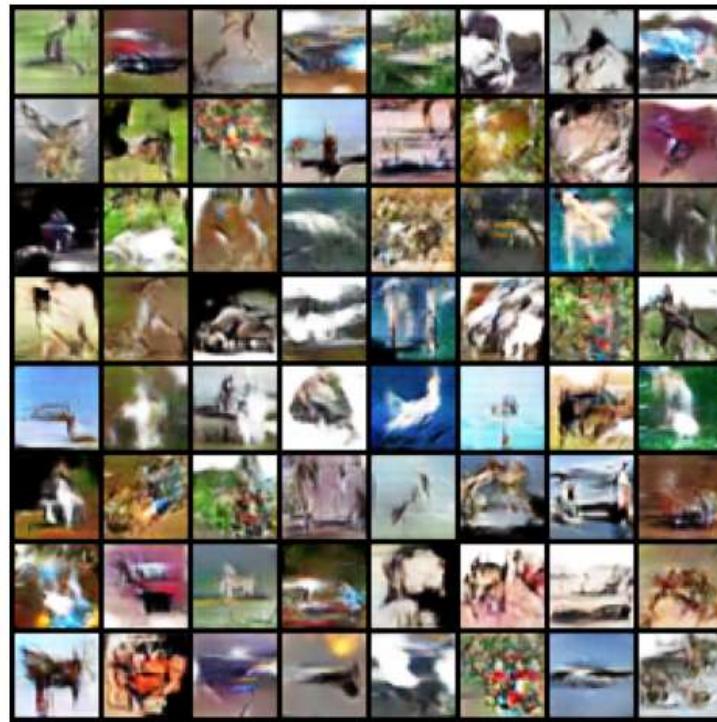
برای تحلیل و بررسی بهتر ویژگی‌های یادگرفته شده توسط مدل‌های GAN، در این بخش از روش کاهش ابعاد داده‌ها با استفاده از t-SNE بهره بردیم. این تکنیک به ما امکان می‌دهد که نمونه‌های تولید شده به عنوان مثال توسط دو مدل DCGAN و GAN را در فضای دو بعدی به تصویر بکشیم و ساختار و توزیع داده‌های تولید شده را به صورت بصری مورد ارزیابی قرار دهیم. با مقایسه نتایج t-SNE برای هر دو مدل می‌توانیم تفاوت‌ها و شباهت‌های کیفیت و تنوع نمونه‌های تولید شده را بهتر درک کنیم و در نتیجه عملکرد مدل‌ها را از دیدگاه درک ویژگی‌های پنهان بررسی کنیم.

### ■ DCGAN:

در این بخش از همان مدل پارت 1 استفاده کردیم و برای این منظور ابتدا همان مدل DCGAN آموزش دیده را به کار گرفتیم و 1000 تصویر تولید کردیم. سپس به منظور بررسی ویژگی‌های استخراج شده از این تصاویر در مقایسه با نمونه‌های واقعی، از مدل ResNet-18 از پیش‌آموزش دیده استفاده کردیم تا بردارهای ویژگی هر تصویر (هم واقعی و هم تولید شده) را استخراج کنیم. این مرحله کمک می‌کند تا با نگاه دقیق‌تر و در فضای ویژگی، کیفیت و تنوع تصاویر تولیدی را ارزیابی کنیم. پس از استخراج بردارهای ویژگی، از t-SNE استفاده کردیم تا این ویژگی‌های با ابعاد بالا را به فضای دو بعدی نگاشت کنیم و امکان مشاهده‌ی بصری خوش‌بندی و توزیع تصاویر را فراهم کنیم. این نگاشت دو بعدی به ما امکان می‌دهد تا شباهت یا اختلاف داده‌های واقعی و تولید شده را به شکل

واض赫تری بررسی کنیم و نقاط قوت یا ضعف مدل را بهتر درک کنیم. در نهایت، نمودارهای حاصل از t-SNE رسم شدند که در آن‌ها می‌توان مشاهده کرد که آیا تصاویر تولیدی مدل DCGAN توانسته‌اند پوشش خوبی از فضای ویژگی داده‌های واقعی داشته باشند یا خیر.

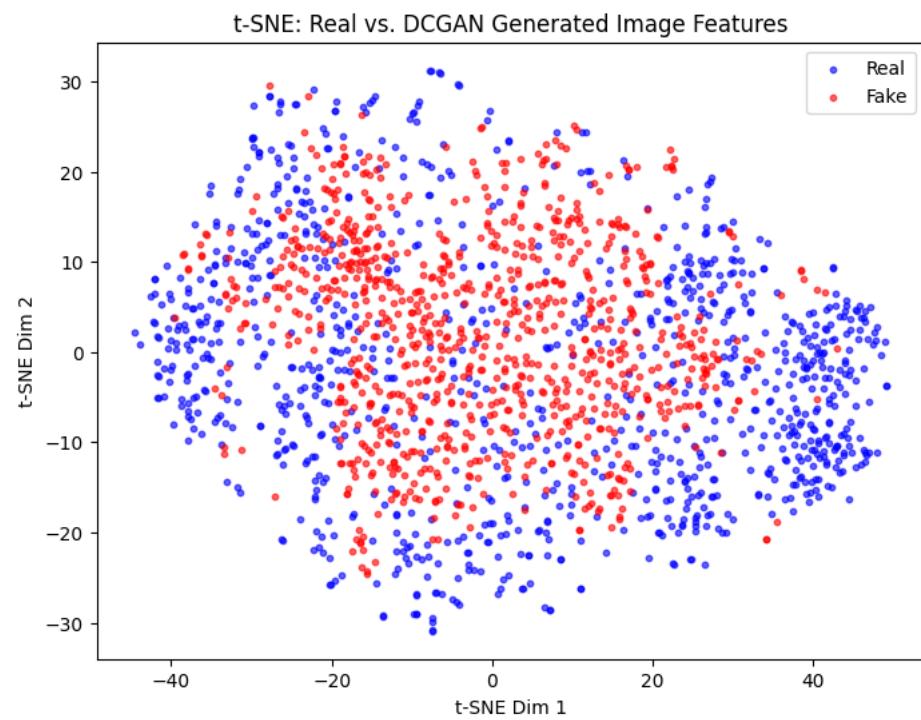
در ادامه به تحلیل خروجی‌های این قسمت که در ادامه نمایش داده شده‌اند می‌پردازیم:



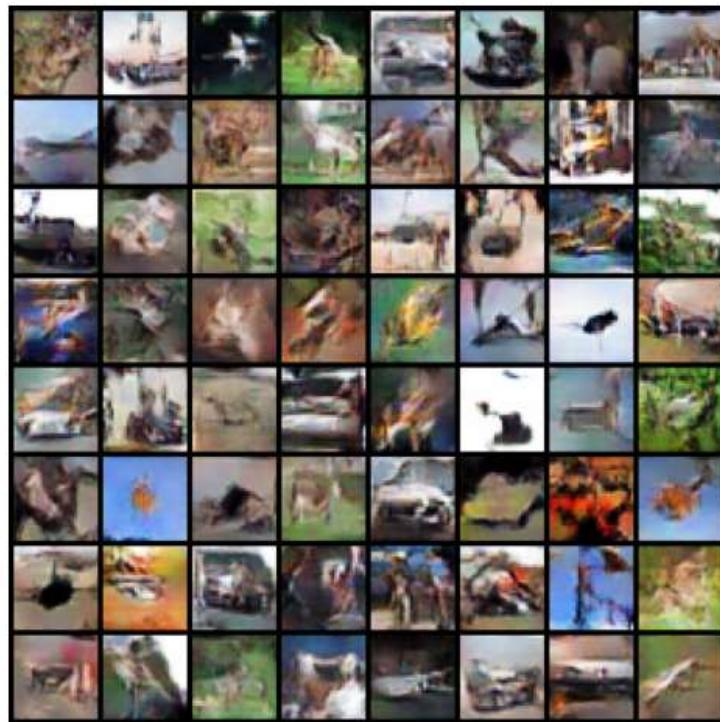
نمودار t-SNE که ویژگی‌های تصاویر واقعی (آبی) و تولیدشده توسط DCGAN (قرمز) را در فضای دو بعدی نشان می‌دهد، بیانگر پراکندگی قابل توجه هر دو دسته است که با همپوشانی گسترده همراه است، اما توزیع تصاویر تولیدشده کمی گسترده‌تر و پراکنده‌تر از تصاویر واقعی به نظر می‌رسد که می‌تواند نشان‌دهنده تنوع بیشتر یا ناهمگونی در تولید تصاویر باشد. مقادیر ارزیابی IS 3.57 و FID 56.98 حاکی از کیفیت متوسط تا قابل قبول تصاویر تولیدشده هستند، با تنوع مناسب (IS) و فاصله نسبی از توزیع واقعی (FID) که نشان‌دهنده تلاش موفق مدل برای تقلید از داده‌های اصلی است. ثبات پراکندگی در نمودار و نزدیک نسبی خوش‌های، معکوس‌کننده تعادل نسبی بین Generator و Discriminator است، هرچند پراکندگی بیشتر تصاویر تولیدشده ممکن است نیاز به تنظیمات بیشتر برای همگرایی دقیق‌تر و یا تعداد اپک بیشتر برای آموزش کافی مدل باشد.

FID 56.98

IS 3.57 ± 0.10

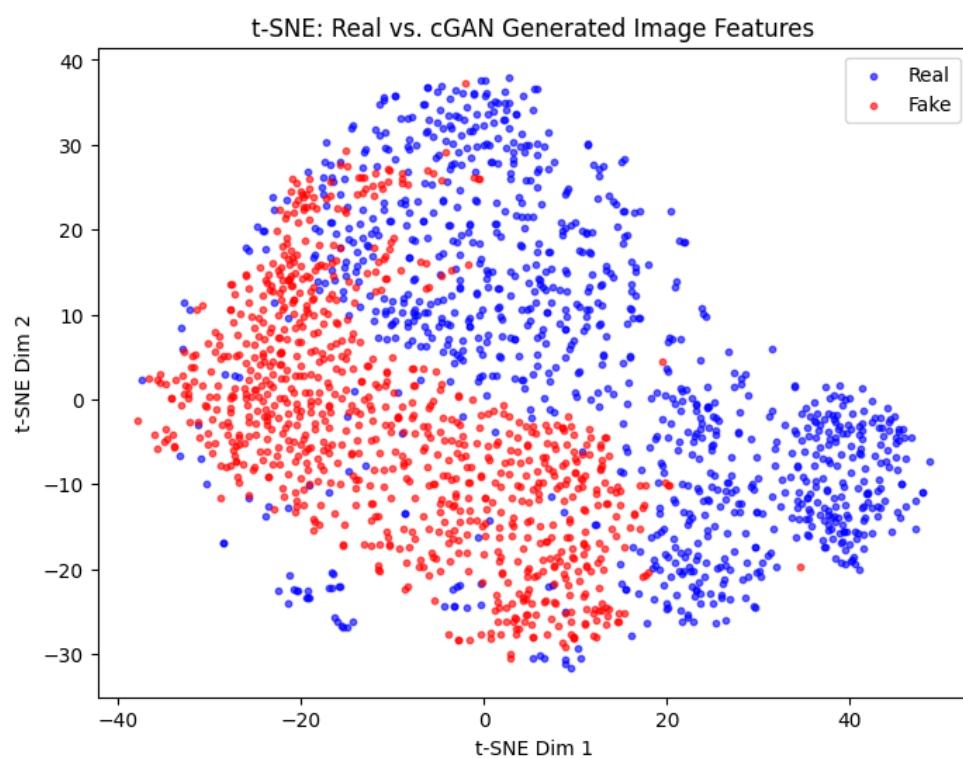


■ CGAN:



نمودار t-SNE که ویژگی‌های تصاویر واقعی (آبی) و تولیدشده توسط cGAN (قرمز) را در فضای دو بعدی نشان می‌دهد، پراکندگی گسترهای را برای هر دو دسته نمایش می‌دهد، با همپوشانی قابل توجه اما توزیع تصاویر تولیدشده که به طور محسوسی از تصاویر واقعی جدا شده و در بخش‌هایی پراکندگی کمتری دارد، که می‌تواند نشان‌دهنده محدودیت در تنوع یا انطباق ناقص با توزیع واقعی باشد. مقادیر ارزیابی IS 3.16 و FID 88.66 حاکی از کیفیت پایین‌تر تصاویر تولیدشده نسبت به مدل‌های بهینه هستند، با تنوع محدود (IS پایین) و فاصله قابل توجه از توزیع واقعی (FID بالا) که نشان‌دهنده چالش‌هایی در تطابق مدل با داده‌های اصلی است. ثبات نسبی پراکندگی در نمودار و جدایی نسبی خوش‌ها، معکس‌کننده تلاش مدل برای حفظ تعادل بین Generator و Discriminator است، اما پراکندگی ناهمگن و فاصله بیشتر تصاویر تولیدشده از واقعی، نشان می‌دهد که عملکرد بدتری نسبت به مدل cGAN که بالاتر نشان دادیم دارد.

FID 88.66 IS 3.16  $\pm$  0.03



## ❖ نقاط قوت و ضعف GANها در مقایسه با سایر مدل‌های مولد مانند VAE‌ها

### -نقاط قوت:

- **کیفیت بصری بسیار بالا GAN‌ها:** به دلیل ساختار رقابتی بین Generator و Discriminator، قادر به تولید نمونه‌های با کیفیت بصری بسیار بالا و جزئیات دقیق هستند. این ویژگی در کاربردهایی مثل تولید چهره‌های واقعی یا هنر دیجیتال، باعث برتری محسوس GAN‌ها نسبت به مدل‌هایی مانند VAE یا Flow‌ها شده است.
- **عدم نیاز به تعریف صریحتابع چکالی احتمال:** برخلاف VAE و Normalizing Flow که برای مدل‌سازی داده‌ها نیاز به تعریف صریح توزیع احتمال دارند، GAN‌ها تنها به یک تابع افتراق برای تشخیص واقعی یا جعلی بودن نمونه نیاز دارند و نیازی به مدل‌سازی دقیق احتمال داده‌ها ندارند.
- **توانایی مدل‌سازی توزیع‌های پیچیده:** معماری‌های GAN به دلیل انعطاف بالای خود قادرند توزیع‌های پیچیده و پرجزئیاتی را از داده‌های واقعی بیاموزنند، در حالی که بسیاری از مدل‌های مولد دیگر مانند VAE معمولاً در مدل‌سازی چنین توزیع‌هایی دچار ساده‌سازی بیش از حد می‌شوند.
- **سرعت تولید بالا در زمان نمونه‌گیری:** برخلاف مدل‌های مولدی مثل PixelCNN که نمونه‌سازی را به صورت ترتیبی و کند انجام می‌دهند، در GAN‌ها می‌توان با یک بار عبور دادن بردار نهفته از Generator، یک تصویر کامل را فوراً تولید کرد.

### -نقاط ضعف:

- عدم دسترسی به احتمال صریح برای داده‌ها GAN: یک مدل مولد implicit است؛ به این معنا که نمی‌توان احتمال تولید یک نمونه خاص (likelihood) را مستقیماً محاسبه کرد. این موضوع باعث محدودیت در کاربردهای آماری یا فشرده‌سازی می‌شود، برخلاف VAE و Flow‌ها که به راحتی likelihood را ارائه می‌دهند.
- چالش در کنترل فضای نهفته: در مدل‌هایی مانند VAE یا Flow، فضای نهفته دارای ساختار مشخصی است که امکان انجام عملیات‌هایی مثل interpolating یا manipulating یا ویژگی‌های خاص فراهم است. اما در GAN‌ها، مگر در نسخه‌هایی خاص مثل InfoGAN یا StyleGAN، این فضا کنترل‌ناپذیرتر و پیچیده‌تر است.
- پایداری پایین در آموزش: برخلاف مدل‌هایی مانند VAE یا PixelCNN که معمولاً روند آموزش نسبتاً پایدار دارند، آموزش GAN ممکن است با نوسان‌های زیاد، فروپاشی حالت، یا واگرایی مواجه شود. این چالش در بخش بعدی به تفصیل بررسی شده است.
- نیاز به تنظیمات حساس و دقیق: عملکرد GAN بسیار به طراحی دقیق شبکه، انتخاب بهینه‌ساز، نرخ یادگیری، استفاده از تکنیک‌هایی مانند label smoothing یا spectral normalization وابسته است. در حالی که مدل‌هایی مثل VAE نسبت به این تنظیمات حساسیت کمتری دارند.

در مجموع GAN‌ها با وجود چالش‌های آموزشی، به دلیل کیفیت بصری بالا و انعطاف‌پذیری در مدل‌سازی توزیع‌های پیچیده، برتری قابل توجهی نسبت به VAE‌ها دارند اما برای بهره‌مندی کامل از پتانسیل آن‌ها، نیاز به تنظیمات دقیق و تکنیک‌های پیشرفته است.

## ❖ چالش‌های آموزش GAN :

آموزش GAN به دلیل ساختار رقابتی و غیرمستقیم آن (به صورت یک بازی مین-مکس بین دو شبکه) با چالش‌های مفهومی و عددی متعددی مواجه است که در ادامه به مهم‌ترین آن‌ها می‌پردازیم:

- **نایابی‌داری در آموزش (Training Instability):** تعادل بین Generator و Discriminator بسیار شکننده است. اگر Discriminator خیلی سریع و قوی یاد بگیرد، Gradients تولید شده برای Generator به شدت ضعیف یا صفر می‌شوند (vanishing gradients)، در نتیجه Generator دیگر قادر به یادگیری مؤثر نیست. از طرف دیگر اگر Generator خیلی زود پیشرفت کند، Discriminator دیگر نمی‌تواند تفاوت نمونه‌های واقعی و جعلی را تشخیص دهد و یادگیری متوقف می‌شود. این بی‌تعادلی منجر به نوسان در عملکرد و افت کیفیت خروجی‌ها می‌شود.
- **فروپاشی حالت (Mode Collapse):** در این حالت، Generator به جای یادگیری توزیع کامل داده‌ها، تنها روی تولید چند نمونه محدود (یا حتی یک نمونه تکراری) تمکز می‌کند. این پدیده زمانی اتفاق می‌افتد که تولید نمونه‌های خاص باعث فربی آسان Discriminator می‌شود، و Generator برای کاهش زیان خود، به تولید آن‌ها بسته می‌کند. نتیجه، تنوع کم در خروجی‌ها و کاهش پوشش توزیع داده‌های واقعی است.
- **همگرایی دشوار (Convergence Difficulty):** برخلاف مدل‌های مولد کلاسیک که معمولاً بهینه‌سازی یکتابع زیان مشخص و محاسب انجام می‌شود، آموزش GAN معادل حل یک بازی دوسویه مین‌مکس است که پاسخ تعادلی آن ممکن است وجود نداشته باشد یا به سختی قابل دستیابی باشد. در عمل، این منجر به نوسانات دائمی در loss‌ها، عدم بهبود کیفیت خروجی، یا حتی افت آن در اواخر آموزش می‌شود.
- **حساسیت شدید به تنظیمات و ابرپارامترها:** یکی از چالش‌های اساسی در آموزش GAN، حساسیت بالای آن به تنظیمات اولیه و انتخاب دقیق ابرپارامترهاست. نرخ یادگیری Generator و Discriminator باید با دقت تنظیم شود، چون اختلاف زیاد بین آن‌ها ممکن است باعث غلبه یکی بر دیگری و نایابی‌داری مدل شود. انتخاب بهینه‌ساز مناسب مانند Adam و استفاده از تکنیک‌هایی مثل Generator Batch Normalization (در Batch Normalization) می‌تواند به پایداری آموزش کمک کند. همچنین روش‌هایی مانند Label Smoothing، Gradient Penalty و Spectral Normalization اغلب برای جلوگیری از نوسانات شدید و فروپاشی حالت به کار می‌روند. در نهایت، تعادل در تعداد بهروزرسانی‌های هر شبکه نیز اهمیت دارد و گاهی لازم است Generator بیشتر از Discriminator آموزش داده شود تا رقابت مؤثر بین آن‌ها حفظ شود..

- مشکل تشخیص معیار توقف مناسب: از آن جا که  $G$  و  $D$  مستقیماً بیانگر کیفیت نمونه‌ها نیستند، یافتن معیاری دقیق برای تشخیص پایان مناسب آموزش دشوار است. مدل ممکن است ظاهراً  $loss$  مناسبی داشته باشد اما خروجی‌هایی بی کیفیت تولید کند، یا بالعکس.

در مجموع، آموزش GAN‌ها به دلیل ساختار رقابتی و پیچیدگی مین‌مکس با چالش‌های نظری ناپایداری، فروپاشی حالت، و همگرایی دشوار مواجه است، که حساسیت به تنظیمات و عدم وجود معیار توقف مناسب آن را پیچیده‌تر می‌کند. با این حال، استفاده از تکنیک‌های پیشرفته‌ی تواند به ثبیت و بهبود فرایند یادگیری کمک کند.

#### ❖ راهکارهای پیشنهادی برای بهبود فرایند یادگیری و ثبیت آموزش

با توجه به چالش‌های جدی در آموزش GAN‌ها مانند ناپایداری، فروپاشی حالت و حساسیت به تنظیمات، مجموعه‌ای از تکنیک‌ها و اصلاحات را برای بهبود فرایند آموزش موجود هستند که در ادامه به مهم‌ترین آن‌ها اشاره می‌کنیم:

- استفاده از **Soft Labels**: در این روش به جای برچسب‌های دقیق 1 یا 0، از مقادیری مانند 0.9 برای تصاویر واقعی استفاده می‌شود. این تکنیک باعث می‌شود Discriminator با اطمینان کمتری عمل کند و فضای یادگیری بهتری برای Generator فراهم شود. ما نیز در تمرین از این روش بهره گرفتیم.
- معماری‌های بهبود یافته مانند **WGAN-GP** و **WGAN**: مدل Wasserstein GAN با جایگزینی تابع  $\text{Wasserstein}$  و حذف تابع  $\text{Sigmoid}$  در خروجی Discriminator (که در این مدل به عنوان "critic" شناخته می‌شود)، پایداری بیشتری را فراهم کرده است. همچنین افزوده شدن تکنیک Gradient Penalty در WGAN-GP به کاهش نوسانات و جلوگیری از انفجار گرادیان کمک کرده است.
- این تکنیک با تحلیل روابط بین نمونه‌های داخل هر  $batch$  به **Mini-batch Discrimination**: کمک می‌کند تا به شباهت بیش از حد تصاویر تولیدی حساس‌تر شود، که می‌تواند خطر فروپاشی حالت (Mode Collapse) را کاهش دهد.
- نرخ یادگیری تفکیک‌شده برای **Discriminator** و **Generator**: تنظیم نرخ یادگیری متفاوت برای دو شبکه می‌تواند به تعادل بهتر در رقابت کمک کند. به طور مثال، در برخی مدل‌ها نرخ یادگیری کمتر برای Discriminator باعث جلوگیری از تسلط سریع آن بر Generator می‌شود.
- نرمال‌سازی مناسب: استفاده از Batch Normalization در لایه‌های Generator باعث همگرایی پایدارتر و سریع‌تر می‌شود. همچنین Spectral Normalization در Discriminator برای کنترل مقادیر گرادیان و بهبود پایداری شبکه پیشنهاد شده است.

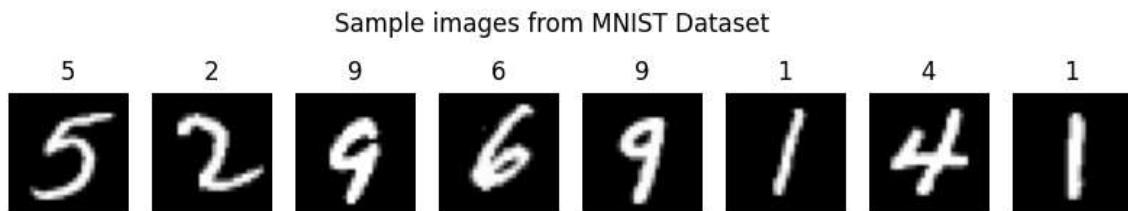
- استفاده از معیارهای ارزیابی مانند IS و FID: برای بررسی کیفیت و تنوع خروجی‌ها، استفاده از شاخص‌های نظری (IS) و Inception Score (Inception Score) و Frechet Inception Distance (FID) ضروری است. این معیارها کمک می‌کنند نه تنها کیفیت بصری بلکه توان مدل در تولید تصاویر متنوع نیز پایش شود.
- افزایش ظرفیت مدل یا استفاده از معماری‌های مدرن‌تر: در مواردی استفاده از معماری‌های مانند BigGAN یا StyleGAN با طراحی دقیق‌تر و بلوک‌های تخصصی‌تر، موجب بهبود چشم‌گیر در کیفیت خروجی و پایداری آموزش شده‌اند.

مجموع این راهکارها اگر به درستی و متناسب با مسئله به کار گرفته شوند، می‌توانند به طرز قابل توجهی روند یادگیری GAN‌ها را ثابت کرده و نتایجی با کیفیت بالا و تنوع مناسب ارائه دهند.

## :Question 2

**.1**

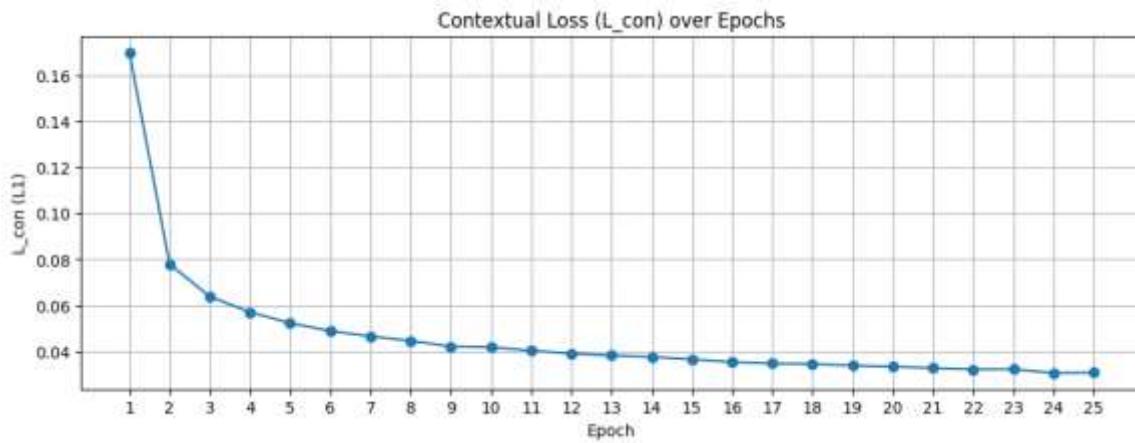
در این پارت از مجموعه داده‌ی استاندارد MNIST که شامل تصاویر عددهای دست‌نویس ۰ تا ۹ استفاده کردیم. داده‌ها با استفاده از کتابخانه torchvision لود و به قالب تنسور تبدیل شدند. در نهایت نیز چند نمونه از نمونه‌های این دیتاست را در ادامه نمایش دادیم:



**.2&3**

در پارت دوم و سوم برای بازسازی تصاویر MNIST، یک خودکدگذار قرینه طراحی کردیم که از یک Encoder و یک Decoder تشکیل شده است. ساختار Encoder شامل چهار لایه‌ی کانولوشنی با فیلترهای 64، 128، 256 و در نهایت 100 است که بازنمایی فشرده تصویر را در قالب یک تنسور  $100 \times 1 \times 1$  تولید می‌کند. Decoder نیز به صورت قرینه عمل کرده و با استفاده از لایه‌های ConvTranspose، تصویر اولیه را بازسازی می‌کند. در تمامی لایه‌ها از ReLU و توابع فعال‌سازی Batch Normalization استفاده شده است.

برای ارزیابی کیفیت بازسازی از تابع Contextual Loss (L<sub>con</sub>) استفاده کردیم که در اینجا با معیار L<sub>1</sub> (MAE) پیاده‌سازی شده و میزان اختلاف پیکسل‌به‌پیکسل بین تصویر اصلی و بازسازی‌شده را محاسبه می‌کند. برای آموزش با توجه به مقاله ذکر شده تنها تصاویر مربوط به یک کلاس (مثلاً کلاس ۰) از دیتاست MNIST فیلتر شده و مورد استفاده قرار گرفتند تا شرایط یادگیری فقط از داده‌های نرمال برقرار باشد. شبکه با استفاده از بهینه‌ساز Adam به مدت 25 اپک آموزش داده شد. در هر اپک مقدار L<sub>con</sub> ثابت و نمودار آن رسم گردید و در ادامه نمودار مربوطه و همچنین نمونه‌هایی از تصاویر واقعی و بازسازی‌شده را برای بررسی عملکرد مدل نیز نمایش داده‌ایم:



نمودار  $L_{con}$  بالا که کاهش Contextual Loss را طی 25 اپک آموزشی نشان می‌دهد، بیانگر بهبود مداوم کیفیت بازسازی تصاویر MNIST است، به‌طوری که مقدار اولیه حدود 0.16 به تدریج به زیر 0.04 در دوره‌های پایانی رسیده است. این کاهش تندرست در مراحل اولیه (تا حدود اپک 5) و سپس روند ملایم‌تر تا پایان حاکی از تطابق سریع اولیه مدل با داده‌ها و همگرایی پایدار در فازهای بعدی است. ثبات کم‌نوسان  $L_{con}$  در اواخر آموزش، منعکس‌کننده تعادل مناسب در فرآیند یادگیری خودکدگذار و توانایی آن در بازسازی دقیق‌تر تصاویر کلاس 0 است که با مشاهده بصری تصاویر بازسازی شده نیز تأیید می‌شود.

$L_{con}: 0.0294$



تصاویر بازسازی شده از مجموعه داده MNIST کلاس 0 که با مقدار  $L_{con} = 0.0294$  ارزیابی شده‌اند، نشان‌دهنده توانایی خوب خودکدگذار در بازسازی شکل کلی اعداد صفر هستند، هرچند برخی جزئیات ظریف (مانند لبه‌های ناهموار) در مقایسه با تصاویر اصلی کمی گم شده‌اند. این مقدار کم  $L_{con}$  تأییدکننده کاهش خطاطی آموزش و تطابق مناسب مدل با داده‌های نرمال است، اما تفاوت‌های بصری جزئی بین تصاویر اصلی و بازسازی شده حاکی از پتانسیل بهبود بیشتر در دقت بازسازی با تنظیمات اضافی یا افزایش دوره‌های آموزشی است.

## .4

در این پارت از یک Encoder مشترک در سه بخش مختلف استفاده شده است: فشرده‌سازی تصویر ورودی، فشرده‌سازی تصویر بازسازی شده ( $\hat{x}$ ) و ورودی شبکه Discriminator. ساختار Encoder شامل چند لایه Transposed Convolution و BatchNorm است که بردار  $z$  را استخراج می‌کند. Decoder نیز با لایه‌های Generator از ترکیب Encoder و Decoder ساخته شده و تصویر  $\hat{x}$  را بازسازی می‌کند. همان Encoder را روی  $\hat{x}$  اعمال می‌کند تا  $\hat{x}$  به دست آید. شبکه AuxiliaryEncoder لایه‌های Fully Connected برای تشخیص واقعی یا جعلی بودن بردار  $z$  استفاده می‌کند. در پایان یک batch نمونه از مدل عبور داده می‌شود و خروجی هر بخش چاپ می‌گردد. این طراحی به خوبی هدف اشتراک‌گذاری Encoder را در سه مرحله مدل محقق کرده است.

```
Input image shape:      torch.Size([64, 1, 32, 32])
Reconstructed x shape: torch.Size([64, 1, 32, 32])
z shape:                torch.Size([64, 100, 1, 1])
ẑ shape:               torch.Size([64, 100, 1, 1])
D(z) shape:             torch.Size([64, 1])
```